

REGRESSION

With JMP software

مقدمه

اطلاعات خودروهای شرکت تولیدکننده اتومبیل جیلی جهت ورود به بازار اتومبیل آمریکا و قیمت‌گذاری محصولاتش در این بازار در اختیار ما قرار داده شده است. در این تمرین قرار است عوامل موثر در تعیین قیمت اتومبیل‌ها را بررسی کرده و در نهایت مدل بهینه‌ای ارائه دهیم که بتواند قیمتی رقابتی برای خودروهای این شرکت مشخص کند.

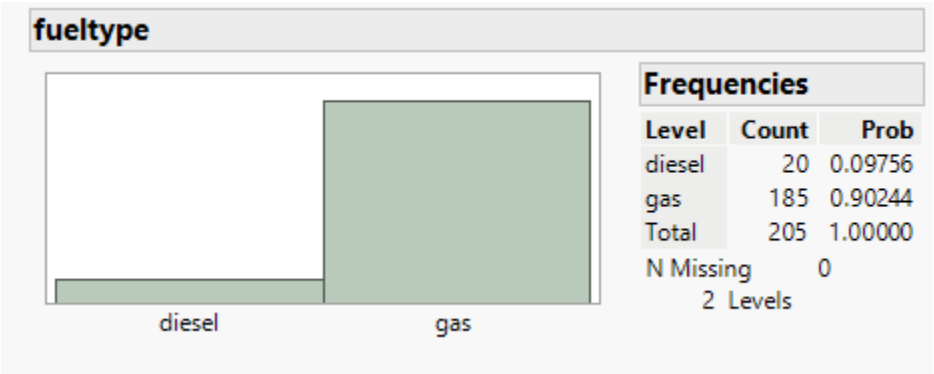
ناهید قلی‌زاده

دوره جامع تربیت تحلیل‌گر داده

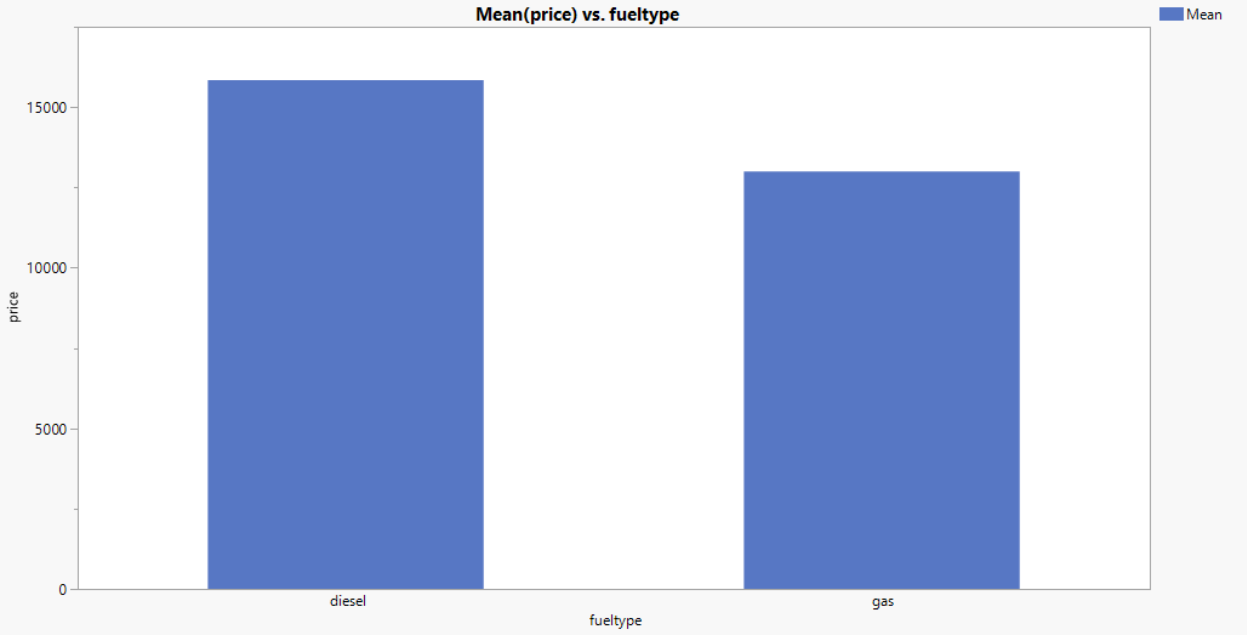
الف) تحلیل تمامی عوامل تاثیرگذار بر روی قیمت با استفاده از ابزارهای آمار توصیفی

در این تحلیل، قیمت خودرو یعنی Price را به عنوان Response در نظر می‌گیریم. مجموعا ۲۲ متغیر داریم که ۹ تای آن‌ها از نوع Categorical می‌باشند که در ادامه تاثیر تک تک آن‌ها را بر روی قیمت بررسی می‌کنیم.

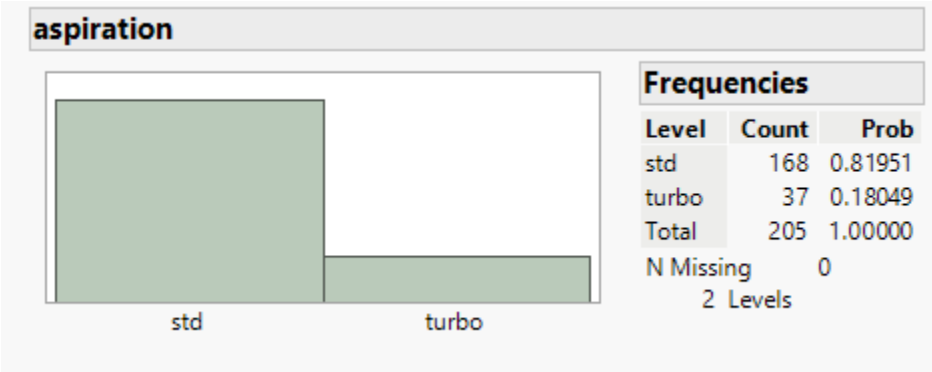
- **Fuel Type (نوع سوخت مصرفی)**
  - ✓ متغیر Categorical
  - ✓ دارای ۲ دسته‌بندی سوخت دیزل و سوخت گاز
  - ✓ ۹۰ درصد خودروها گازسوز هستند.



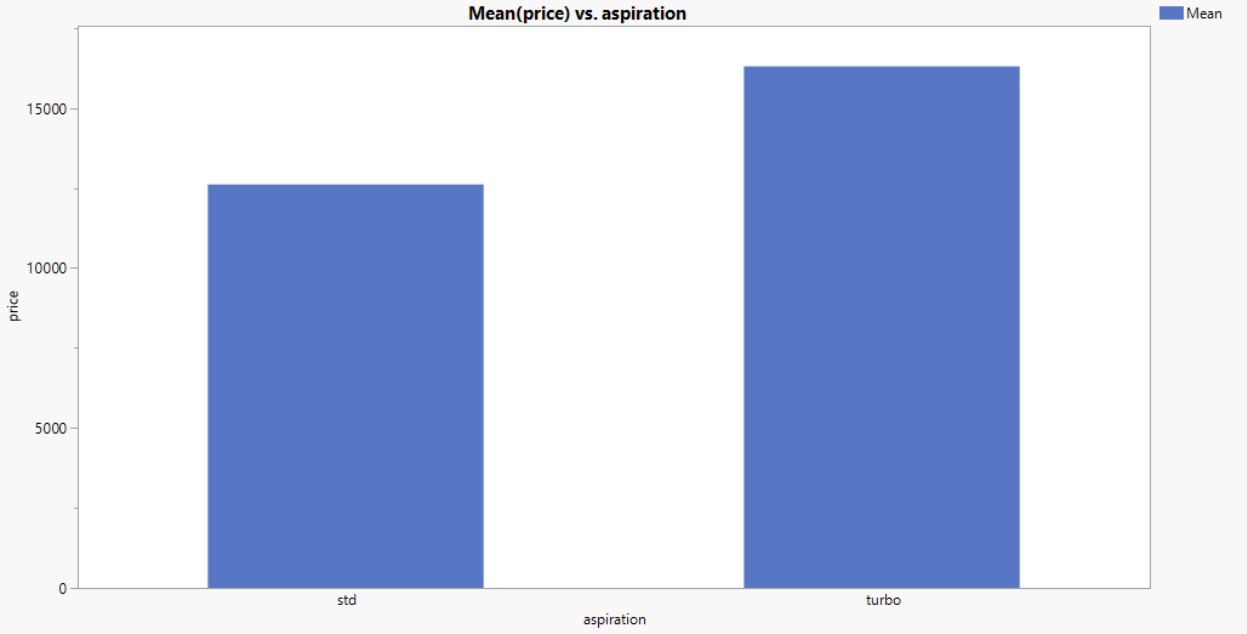
همان‌طور که در نمودار bar زیر مشخص است، میانگین قیمت خودروهای دیزلی از خودروهای گازسوز بیشتر است. (بالای ۱۵۰۰۰)



- **Asipration (نوع موتور خودرو از نظر توربو بودن یا استاندارد بودن)**
  - ✓ متغیر Categorical
  - ✓ دارای ۲ دسته‌بندی موتور استاندارد و موتور توربو
  - ✓ حدود ۸۲ درصد خودروها موتور استاندارد دارند.



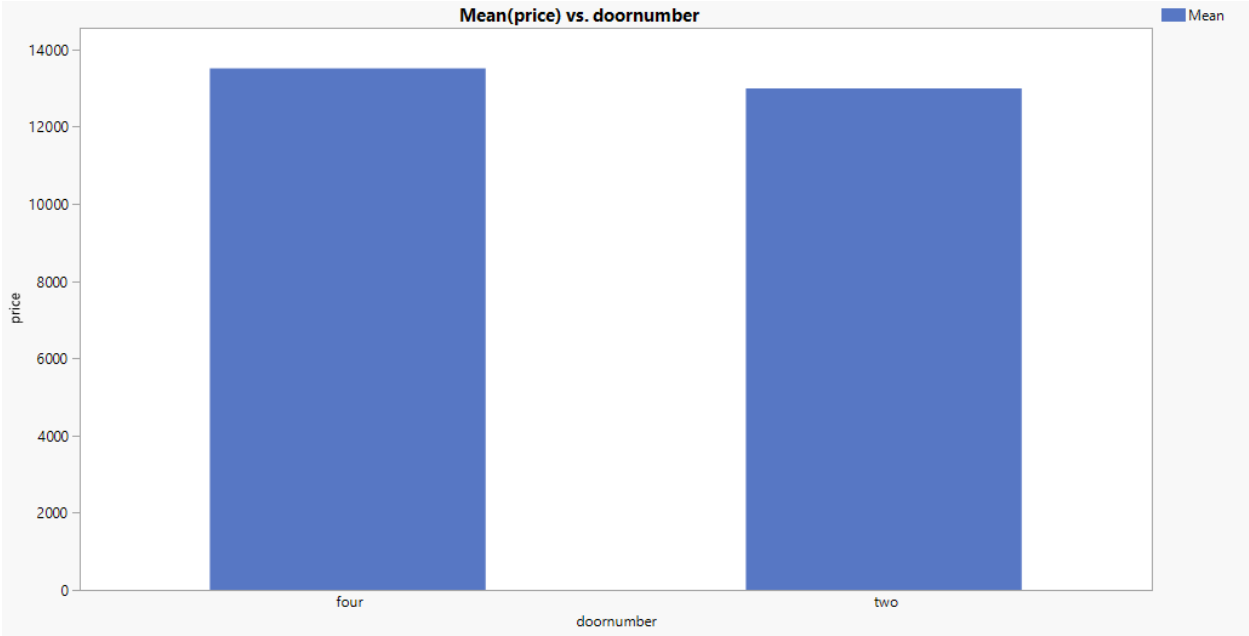
همان‌طور که در نمودار زیر مشاهده می‌کنید، به طور میانگین اگر برای خودروها موتور توربو کار شده باشد، قیمتشان بالاتر می‌رود.



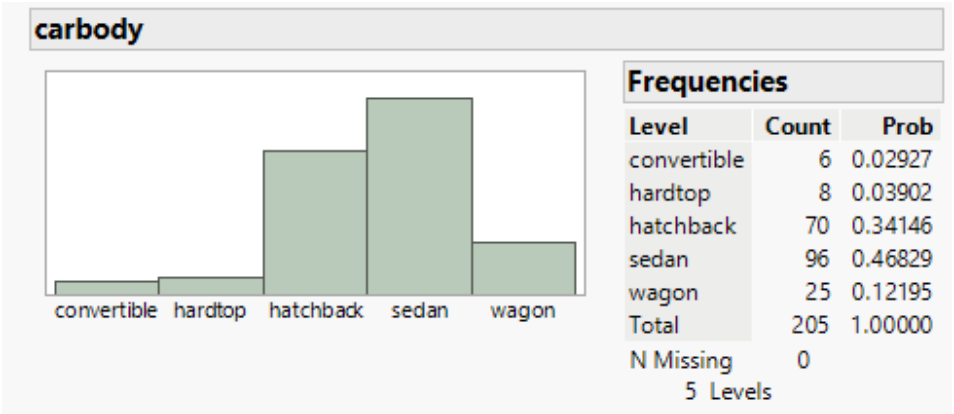
- **Door number (تعداد درب‌ها)**
  - ✓ متغیر Categorical
  - ✓ دارای ۲ دسته‌بندی ۴ در و ۲ در
  - ✓ ۵۶ درصد خودروها ۴ در دارند.



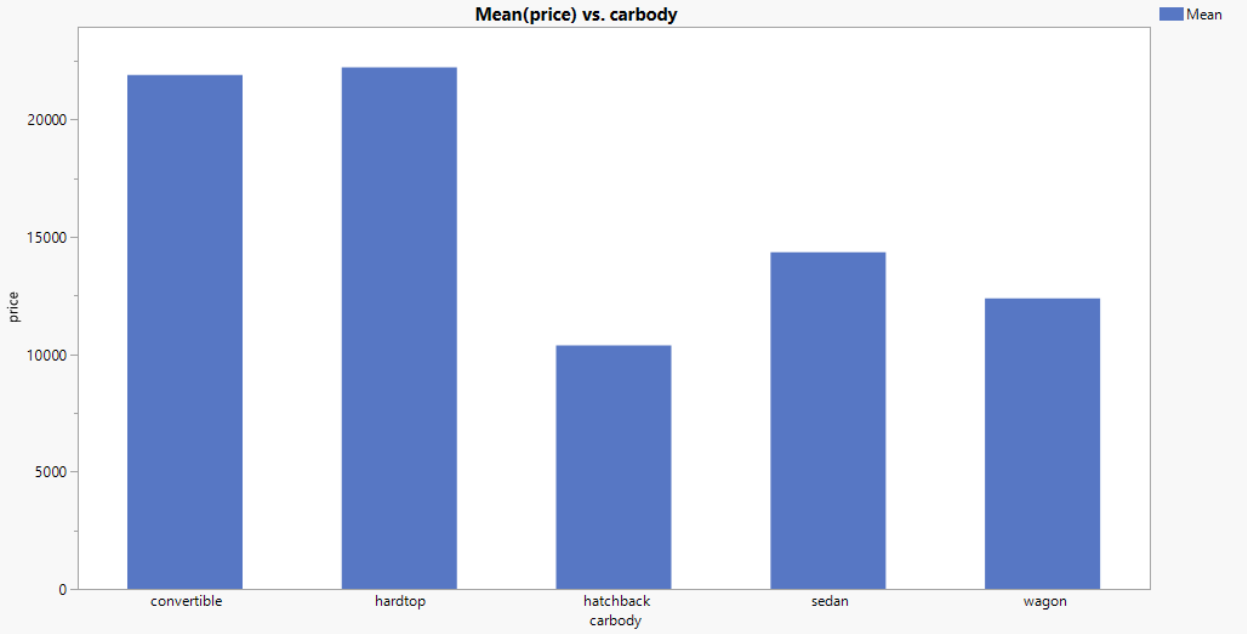
مشخصا تعداد درهای خودرو خیلی روی قیمت آن تاثیرگذار نیست.



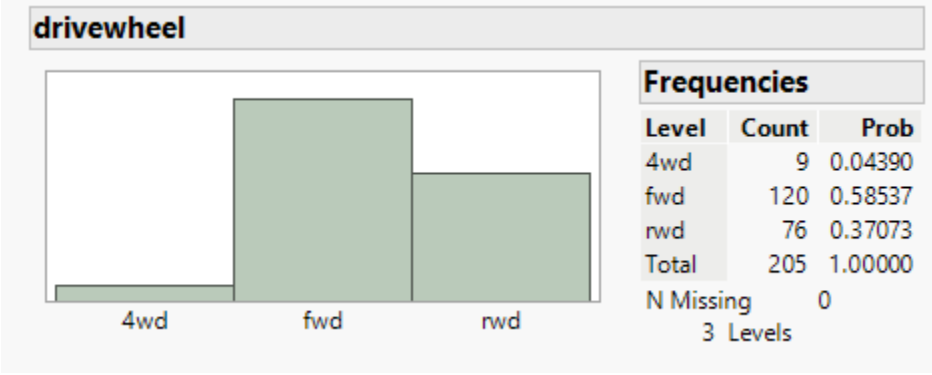
- **Car body (نوع خودرو از لحاظ هاچ بک بودن، سدان و ...)**
  - ✓ متغیر Categorical
  - ✓ دارای ۵ دسته‌بندی واگن، سدان، هاچبک، سقف هارد تاپ و کروک (کانورتیبل)
  - ✓ خودروها بیشتر به سبک سدان طراحی شده‌اند. (۴۶ درصد)



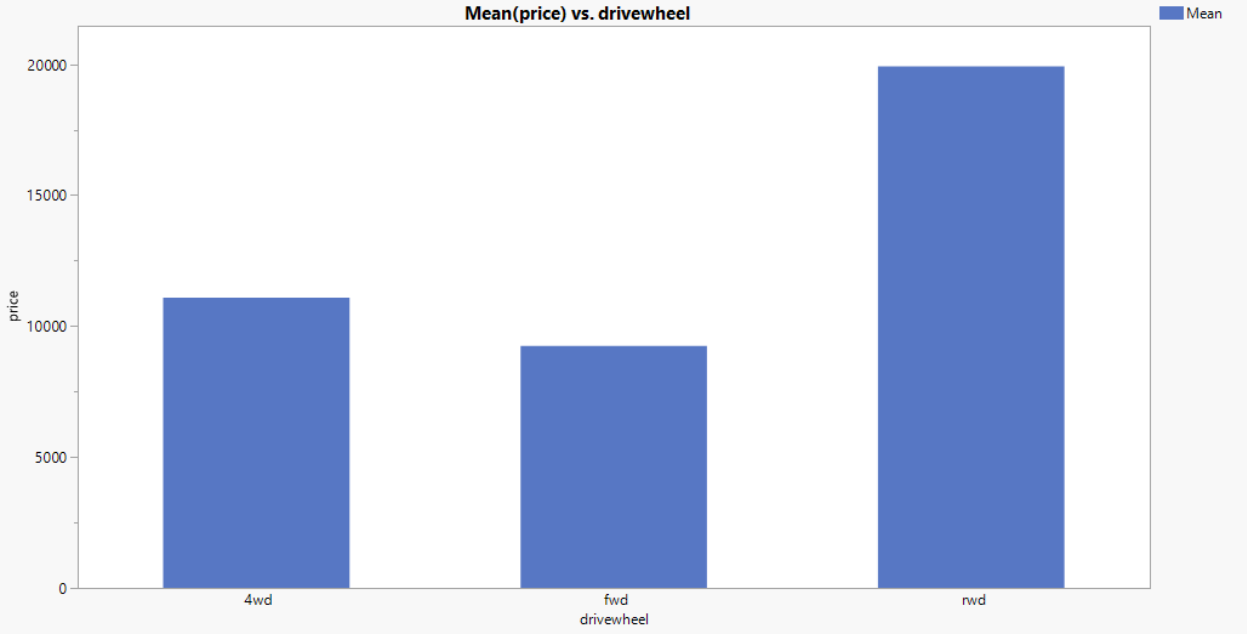
کمترین قیمت متعلق به خودروهای دسته هاچ بک است.



- **Drive wheel (چرخ محرک خودرو)**
  - ✓ متغیر Categorical
  - ✓ دارای ۳ دسته‌بندی دیفرانسیل عقب، دیفرانسیل جلو و 4wd
  - ✓ تعداد ۱۲۰ خودرو از مجموع ۲۰۵ خودرو، دیفرانسیل جلو (fwd) هستند.



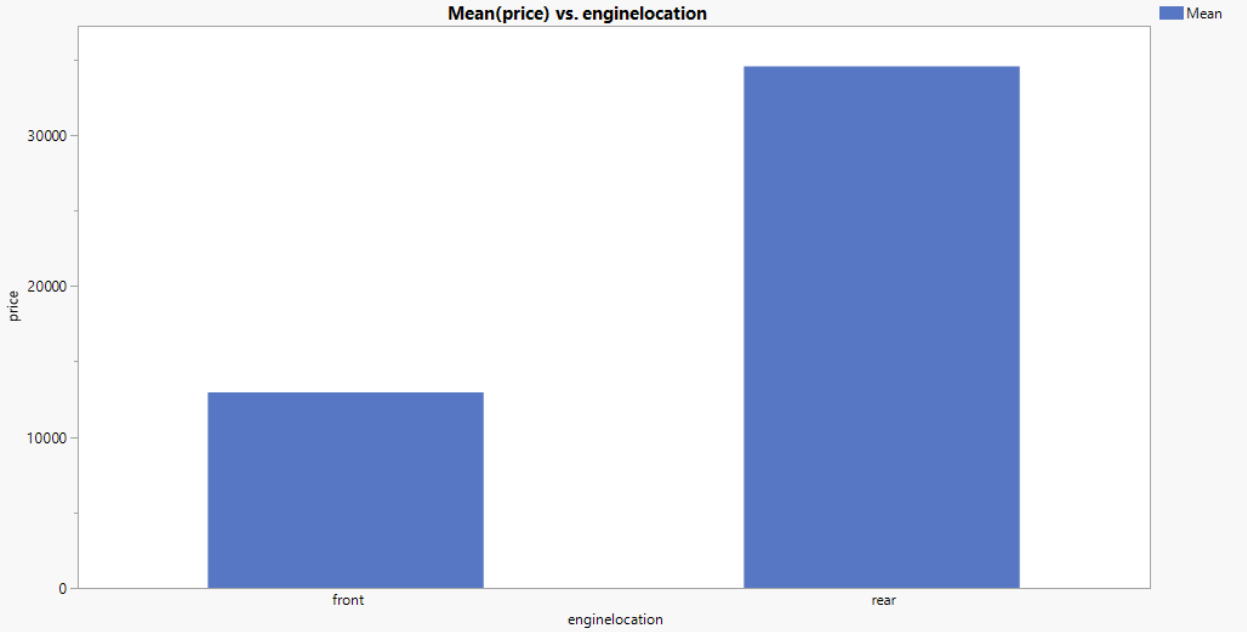
ماشین‌های دیفرانسیل عقب در مقایسه با دو دسته دیگر، قیمت بالاتری دارند. (حدود ۲۰ هزار دلار)



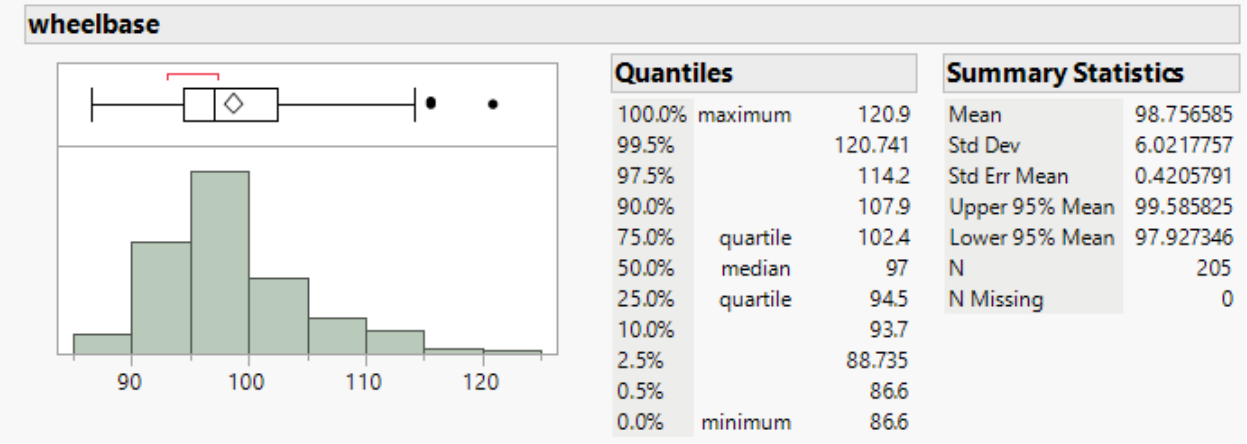
- **Enginelocation (محل قرارگیری موتور خودرو)**
  - ✓ متغیر Categorical
  - ✓ دارای ۲ دسته‌بندی عقب و جلو
  - ✓ در اکثر خودروها یعنی ۹۸ درصدشان، محل قرارگیری موتور در جلوی بدنه تعبیه شده است.



با اینکه تنها ۱ درصد یعنی ۳ نوع خودرو موتورشان در انتهای بدنه کار شده، طبق نمودار زیر، این ویژگی در قیمت خودرو بسیارتاثیرگذار بوده است.



- **Wheelbase (فاصله بین دو محور خودرو)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۸۶.۶ تا ۱۲۰.۹
  - ✓ فاصله بین دو محور خودروها به طور متوسط (میانگین داده‌ها): ۹۸.۷ سانت
  - ✓ انحراف معیار داده‌ها: ۶



Quantiles

100.0%	maximum	120.9
99.5%		120.741
97.5%		114.2
90.0%		107.9
75.0%	quartile	102.4
50.0%	median	97
25.0%	quartile	94.5
10.0%		93.7
2.5%		88.735
0.5%		86.6
0.0%	minimum	86.6

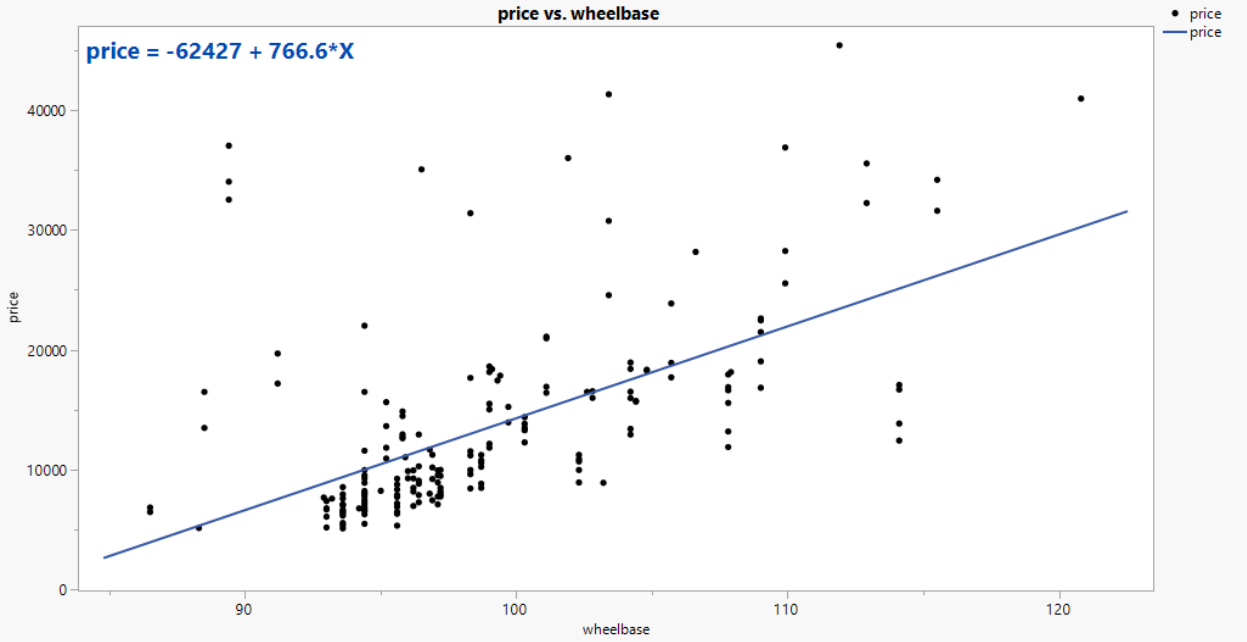
Summary Statistics

Mean	98.756585
Std Dev	6.0217757
Std Err Mean	0.4205791
Upper 95% Mean	99.585825
Lower 95% Mean	97.927346
N	205
N Missing	0

طبق نمودار scatter زیر:

- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین فاصله بین دو محور خودرو با قیمت آن مستقیم
- ✓ با افزایش فاصله بین دو محور خودرو، قیمت خودرو نیز افزایش می‌یابد.

✓ بر اساس معادله خط زیر، با هر ۱ سانت افزایش فاصله بین دو محور خودرو، میانگین قیمت خودرو ۷۶۶.۶ دلار افزایش می‌یابد.



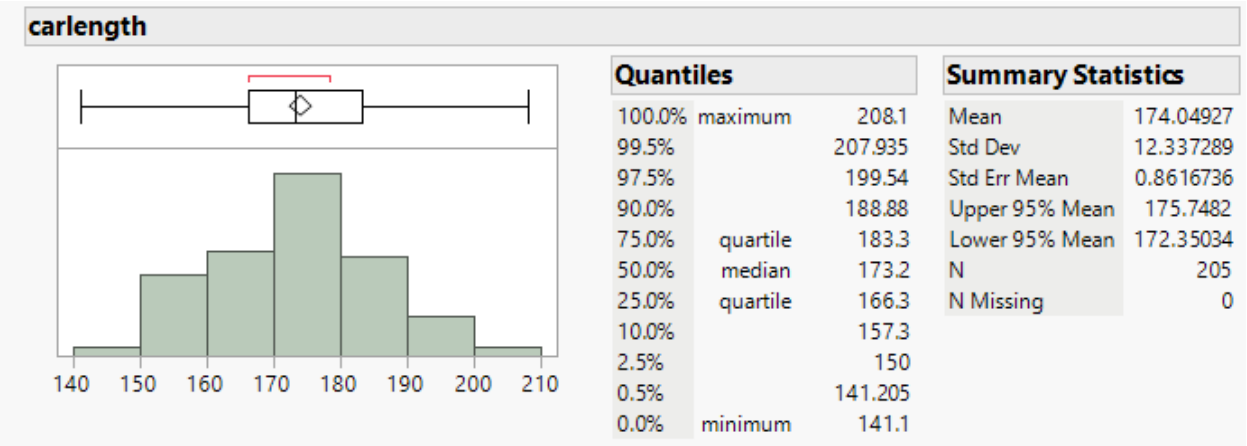
- **Carlength (طول)**

✓ متغیر Numerical

✓ بازه مقادیر داده: از ۱۴۱.۱ تا ۲۰۸.۱

✓ طول خودروها به طور متوسط (میانگین داده‌ها): ۱۷۴ سانت

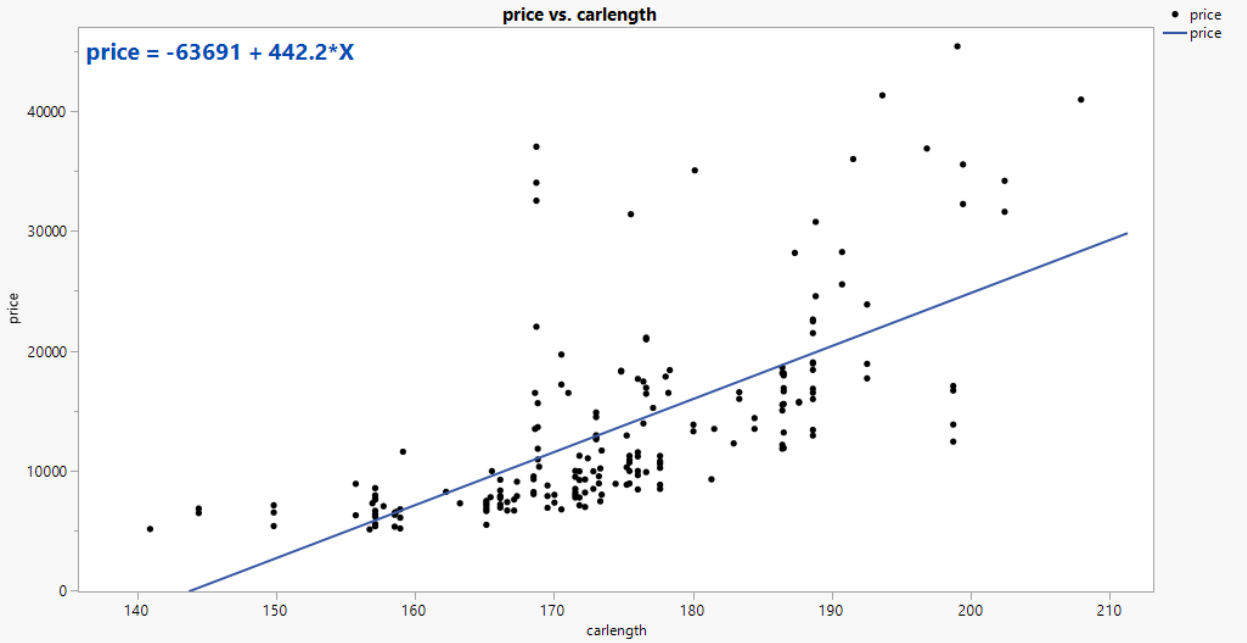
✓ انحراف معیار داده‌ها: ۱۲.۳



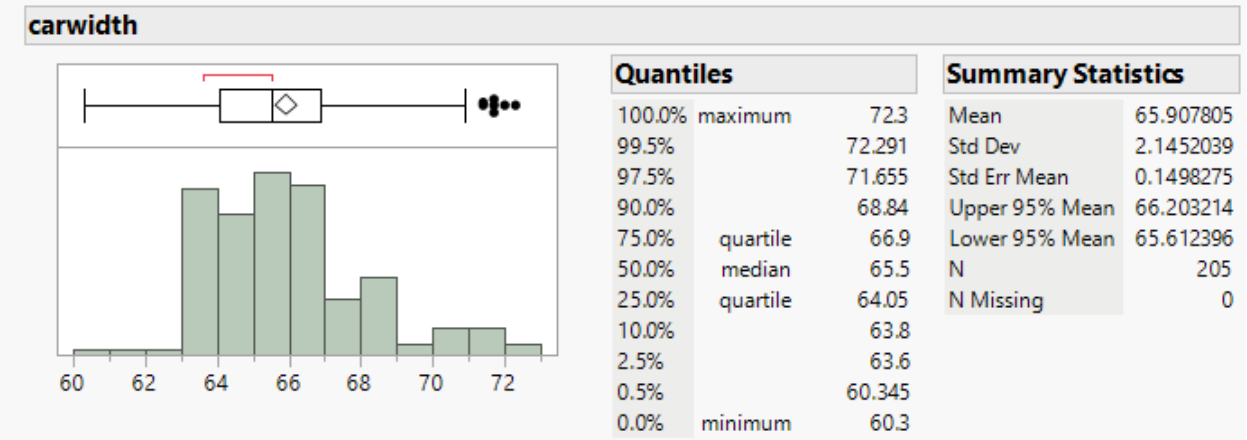
✓ شیب خط رگرسیون مثبت و صعودی

✓ رابطه بین طول خودرو با قیمت آن مستقیم

- ✓ با افزایش طول خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ سانت افزایش طول خودرو، میانگین قیمت خودرو ۴۴۲.۲ دلار افزایش می‌یابد.



- **Carwide (عرض)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۶۰.۳ تا ۷۲.۳
  - ✓ طول خودروها به طور متوسط (میانگین داده‌ها): ۶۵.۹ سانت
  - ✓ انحراف معیار داده‌ها: ۲.۱



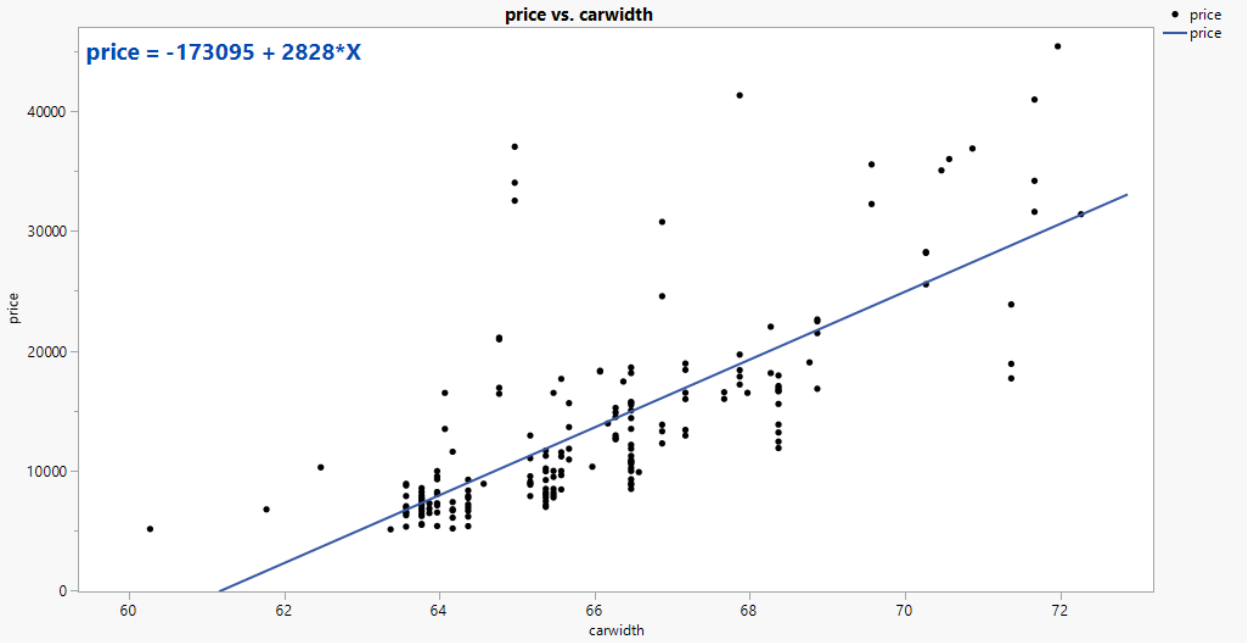
Quantiles

100.0%	maximum	72.3
99.5%		72.291
97.5%		71.655
90.0%		68.84
75.0%	quartile	66.9
50.0%	median	65.5
25.0%	quartile	64.05
10.0%		63.8
2.5%		63.6
0.5%		60.345
0.0%	minimum	60.3

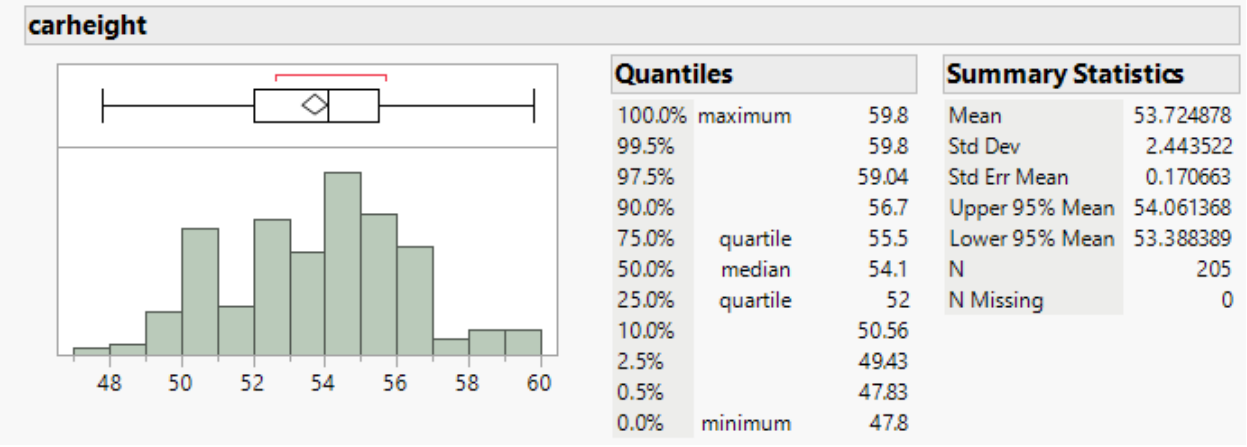
Summary Statistics

Mean	65.907805
Std Dev	2.1452039
Std Err Mean	0.1498275
Upper 95% Mean	66.203214
Lower 95% Mean	65.612396
N	205
N Missing	0

- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین عرض خودرو با قیمت آن مستقیم
- ✓ با افزایش عرض خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ سانت افزایش عرض خودرو، میانگین قیمت خودرو ۲۸۲۸ دلار افزایش می‌یابد.



- **CarHeight (ارتفاع خودرو)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۴۷.۸ تا ۵۹.۸
  - ✓ ارتفاع خودروها به طور متوسط (میانگین داده‌ها) ۵۳.۷ سانت
  - ✓ انحراف معیار داده‌ها: ۲.۴



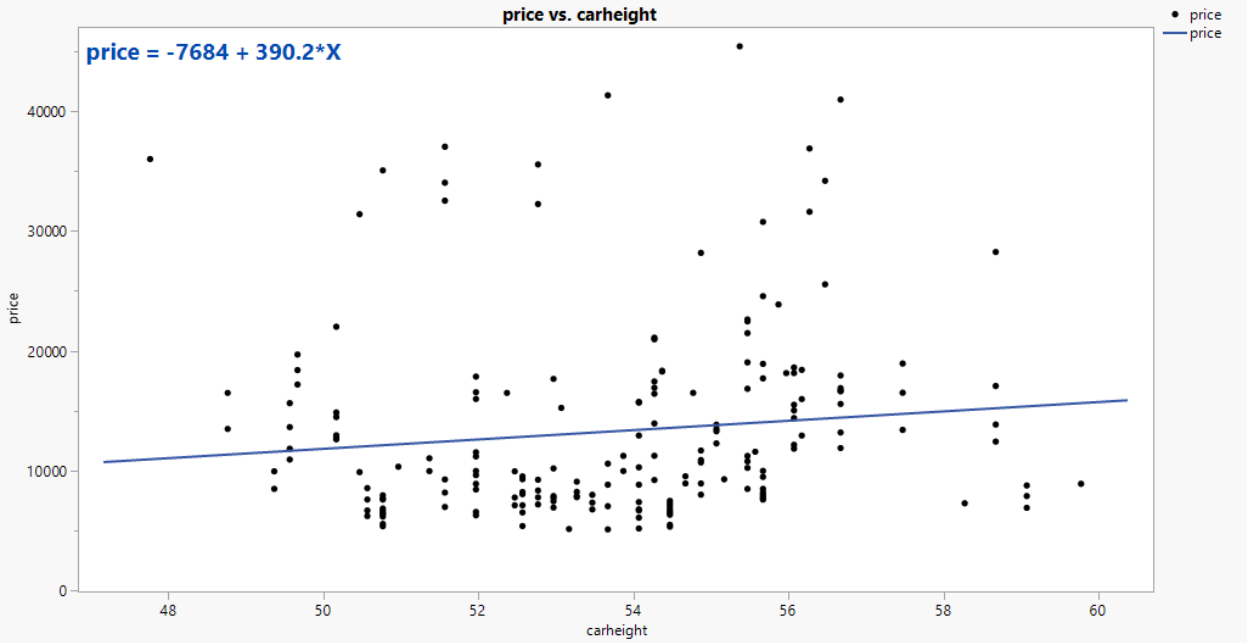
Quantiles

100.0%	maximum	59.8
99.5%		59.8
97.5%		59.04
90.0%		56.7
75.0%	quartile	55.5
50.0%	median	54.1
25.0%	quartile	52
10.0%		50.56
2.5%		49.43
0.5%		47.83
0.0%	minimum	47.8

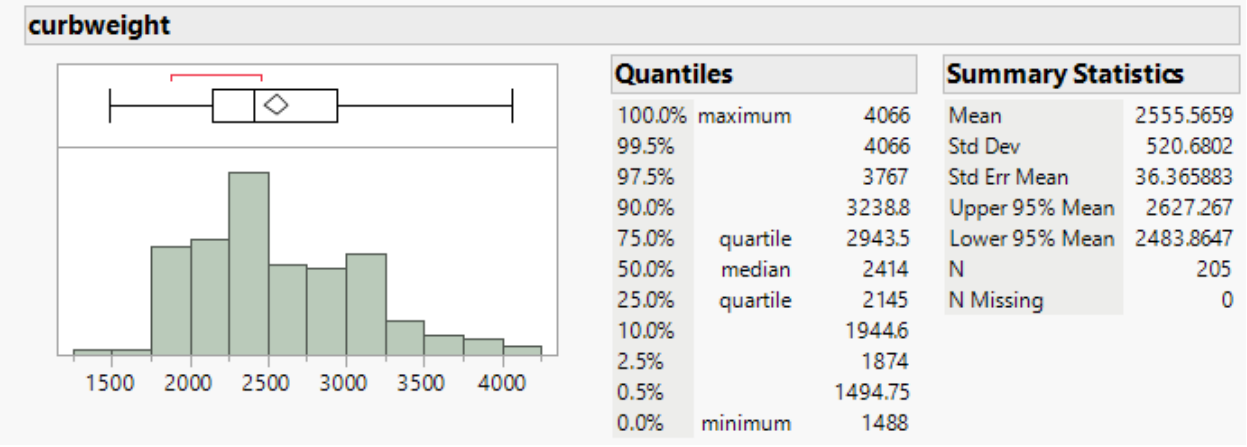
Summary Statistics

Mean	53.724878
Std Dev	2.443522
Std Err Mean	0.170663
Upper 95% Mean	54.061368
Lower 95% Mean	53.388389
N	205
N Missing	0

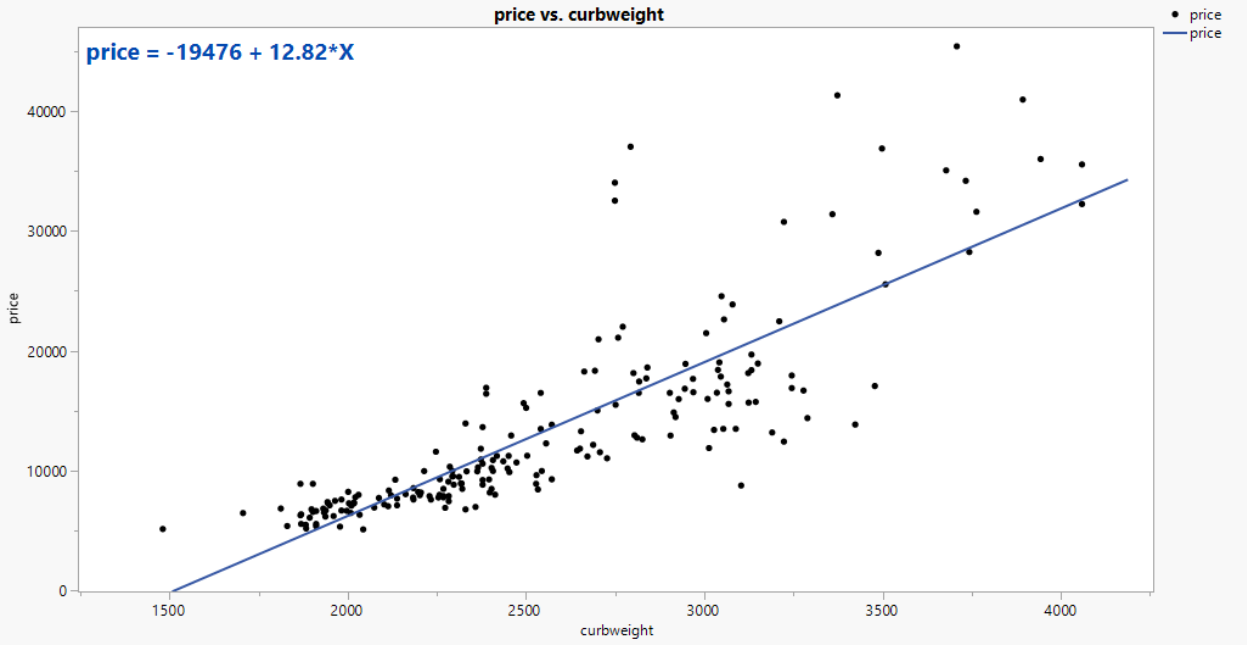
- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین ارتفاع خودرو با قیمت آن مستقیم
- ✓ با افزایش ارتفاع خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ سانت افزایش ارتفاع خودرو، میانگین قیمت خودرو ۳۹۰.۲ دلار افزایش می‌یابد.



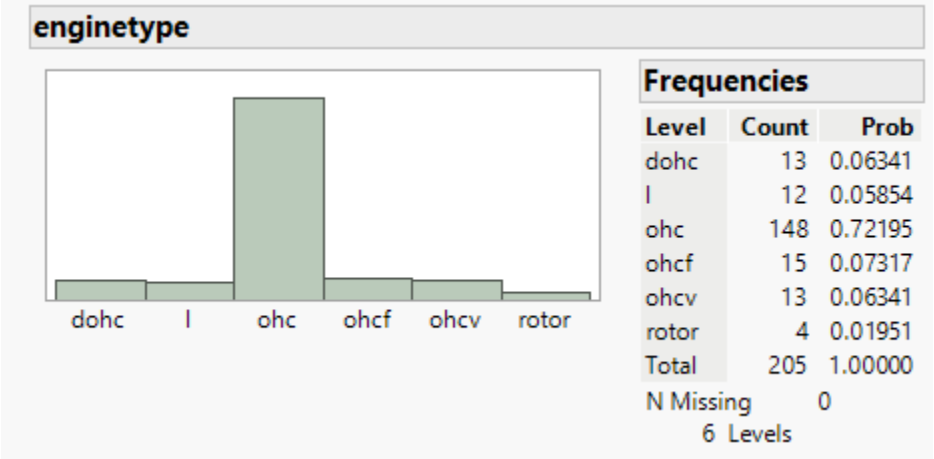
- **Cube weight (وزن خودرو)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۱۴۸۸ تا ۴۰۶۶
  - ✓ وزن خودروها به طور متوسط (میانگین داده‌ها): ۶۵.۹ کیلوگرم
  - ✓ انحراف معیار داده‌ها: ۵۲۰.۶



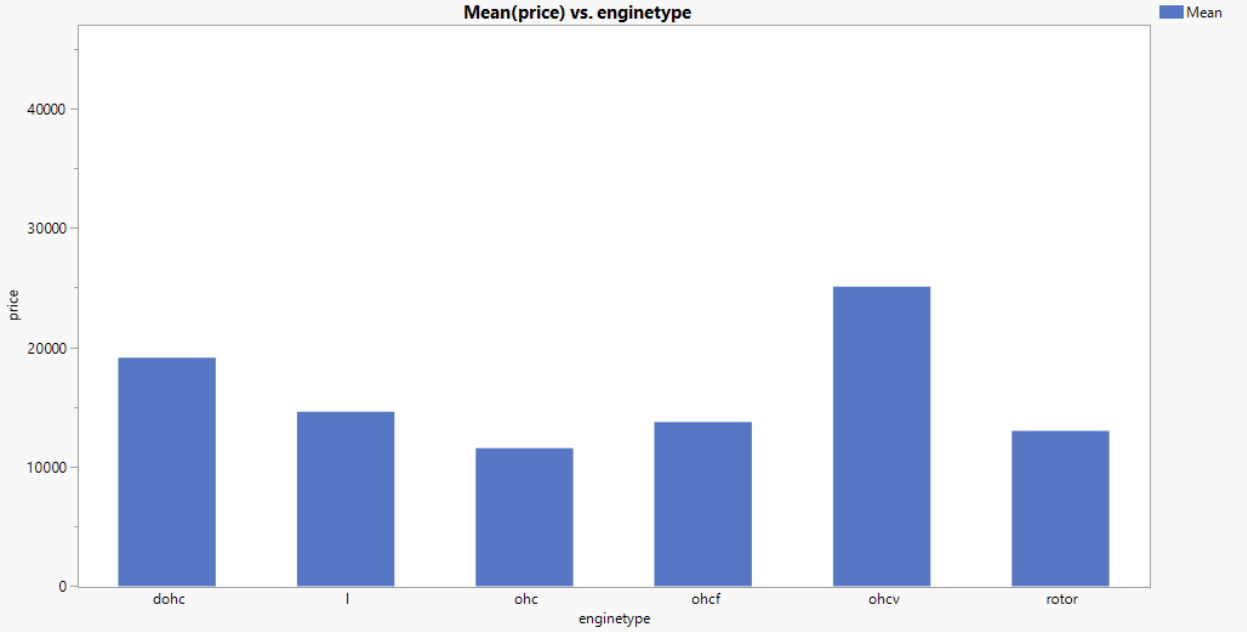
- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین وزن خودرو با قیمت آن مستقیم
- ✓ با افزایش وزن خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ کیلوگرم افزایش وزن خودرو، میانگین قیمت خودرو ۱۲.۸۲ دلار افزایش می‌یابد.



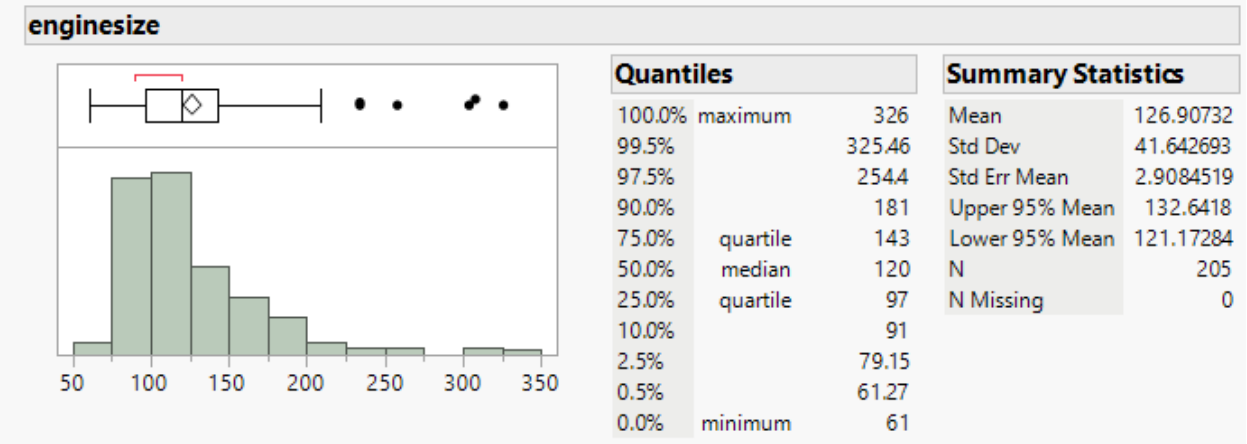
- **Enginetype (نوع موتور)**
  - ✓ متغیر Categorical
  - ✓ دارای ۶ دسته‌بندی
  - ✓ پرتکرارترین نوع موتور در خودروها ohc است با میزان ۷۲ درصد.



از نظر نوع موتور بیشترین قیمت متعلق به خودروهایی است که موتور ohcv دارند.



- **Enginesize (سایز موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۶۱ تا ۳۲۶
  - ✓ سایز موتور خودروها به طور متوسط (میانگین داده‌ها): ۱۲۶.۹
  - ✓ انحراف معیار داده‌ها: ۴۱.۶

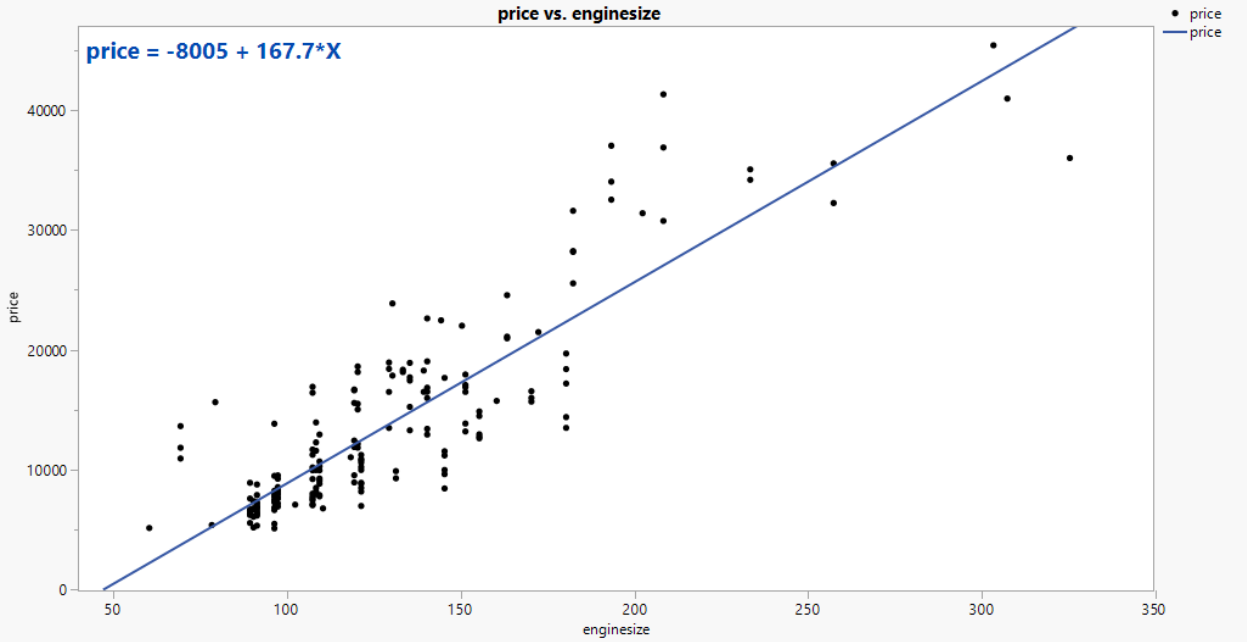


Quantiles		
100.0%	maximum	326
99.5%		325.46
97.5%		254.4
90.0%		181
75.0%	quartile	143
50.0%	median	120
25.0%	quartile	97
10.0%		91
2.5%		79.15
0.5%		61.27
0.0%	minimum	61

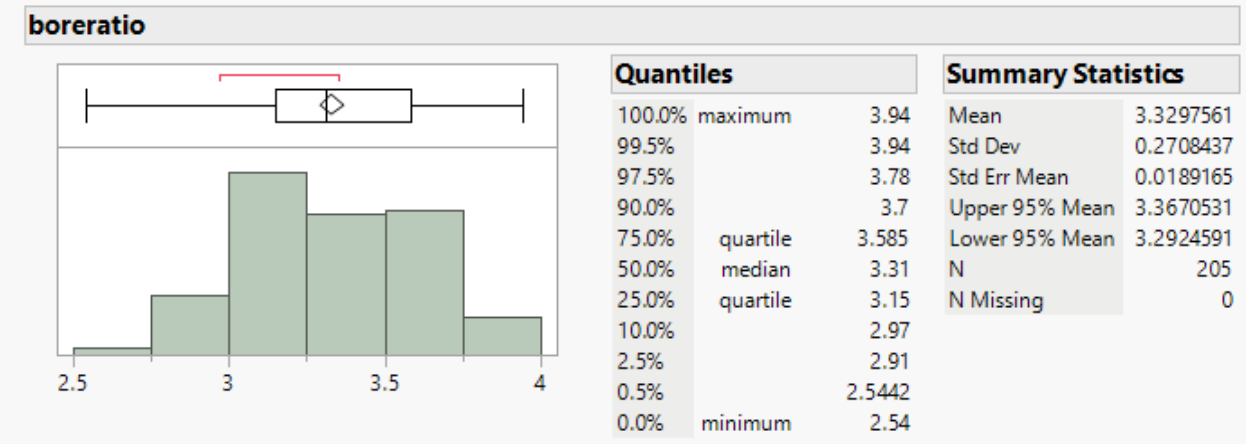
Summary Statistics	
Mean	126.90732
Std Dev	41.642693
Std Err Mean	2.9084519
Upper 95% Mean	132.6418
Lower 95% Mean	121.17284
N	205
N Missing	0

- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین سایز موتور خودرو با قیمت آن مستقیم
- ✓ با افزایش سایز موتور خودرو، قیمت خودرو نیز افزایش می‌یابد.

- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش سایز موتور خودرو، میانگین قیمت خودرو ۱۶۷.۷ دلار افزایش می‌یابد.



- **Boreratio (نسبت بین ابعاد قطر منفذ سیلندر موتور به طول کورس پیستون (مشخصه قدرت و گشتاور موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۲.۵۴ تا ۳.۹۴
  - ✓ مقدار Boreratio خودروها به طور متوسط (میانگین داده‌ها): ۳.۳۲
  - ✓ انحراف معیار داده‌ها: ۰.۲۷



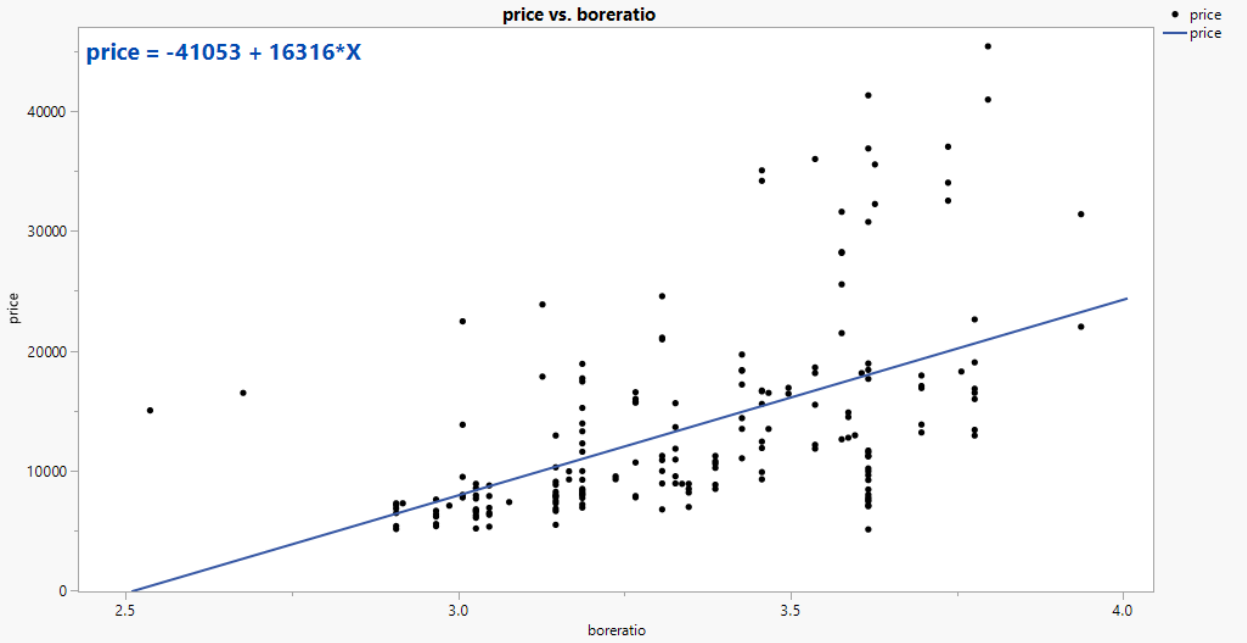
Quantiles

100.0%	maximum	3.94
99.5%		3.94
97.5%		3.78
90.0%		3.7
75.0%	quartile	3.585
50.0%	median	3.31
25.0%	quartile	3.15
10.0%		2.97
2.5%		2.91
0.5%		2.5442
0.0%	minimum	2.54

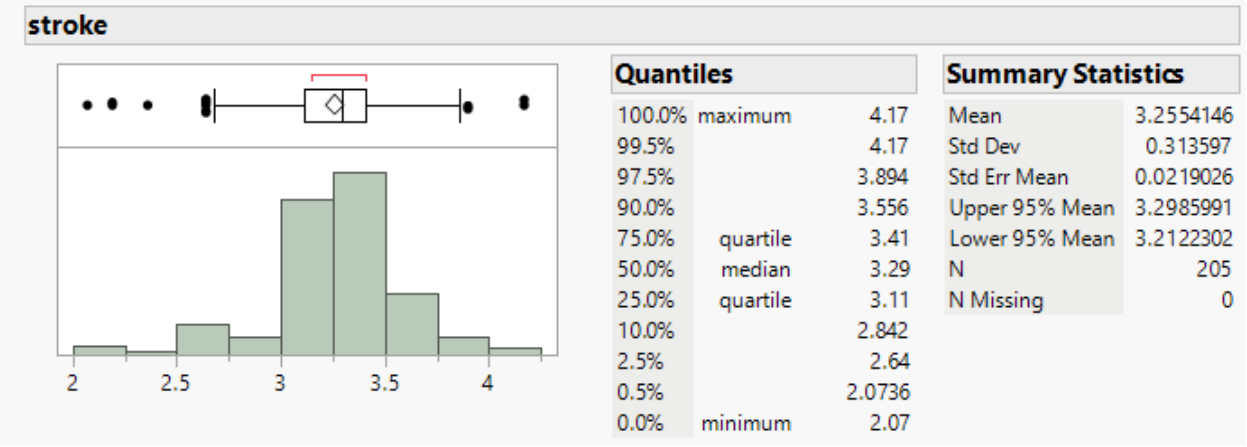
Summary Statistics

Mean	3.3297561
Std Dev	0.2708437
Std Err Mean	0.0189165
Upper 95% Mean	3.3670531
Lower 95% Mean	3.2924591
N	205
N Missing	0

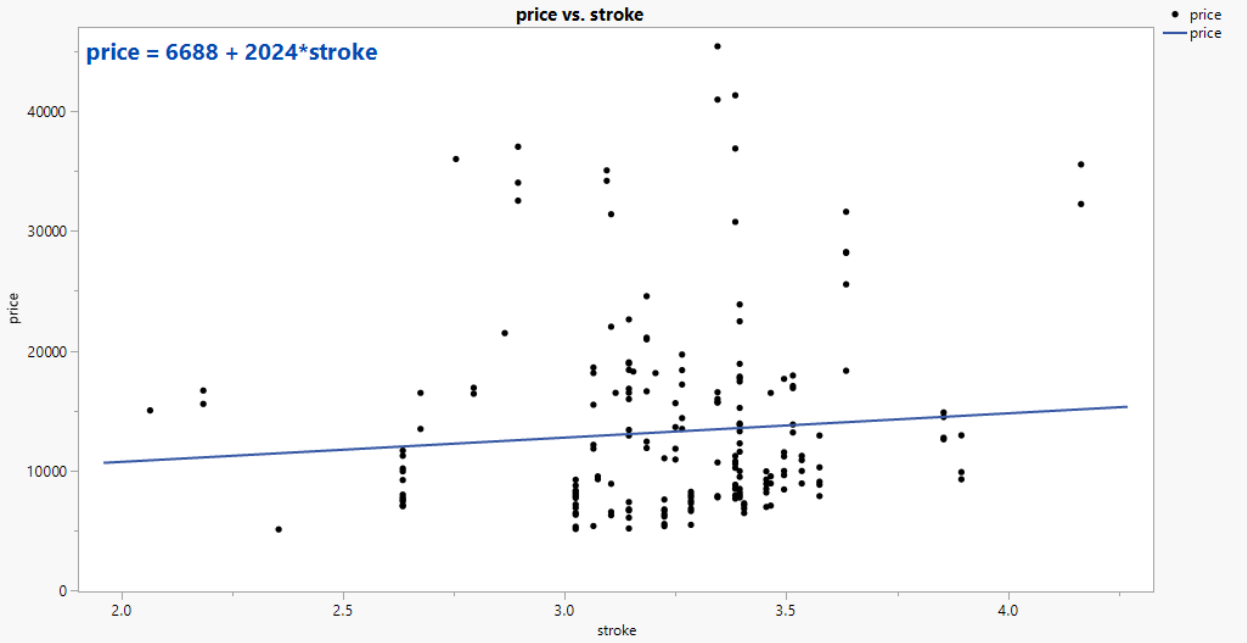
- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین Boreratio خودرو با قیمت آن مستقیم
- ✓ با افزایش Boreratio خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش Boreratio خودرو، میانگین قیمت خودرو ۱۶۳۱۶ دلار افزایش می‌یابد.



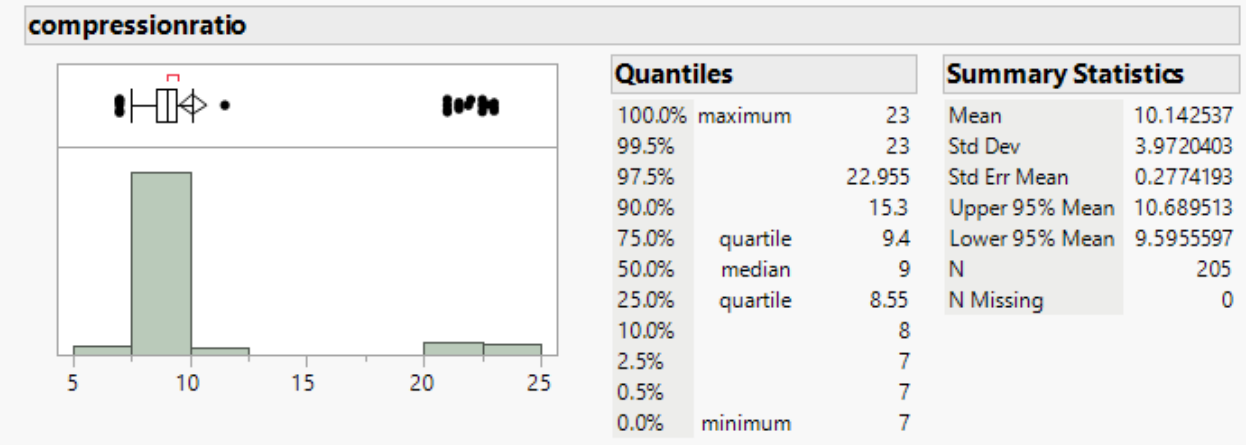
- **Stroke (مسافت طی شده توسط پیستون در طول هر چرخه)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۲.۰۷ تا ۴.۱۷
  - ✓ مقدار Stroke خودروها به طور متوسط (میانگین داده‌ها): ۳.۲۵
  - ✓ انحراف معیار داده‌ها: ۰.۳۱



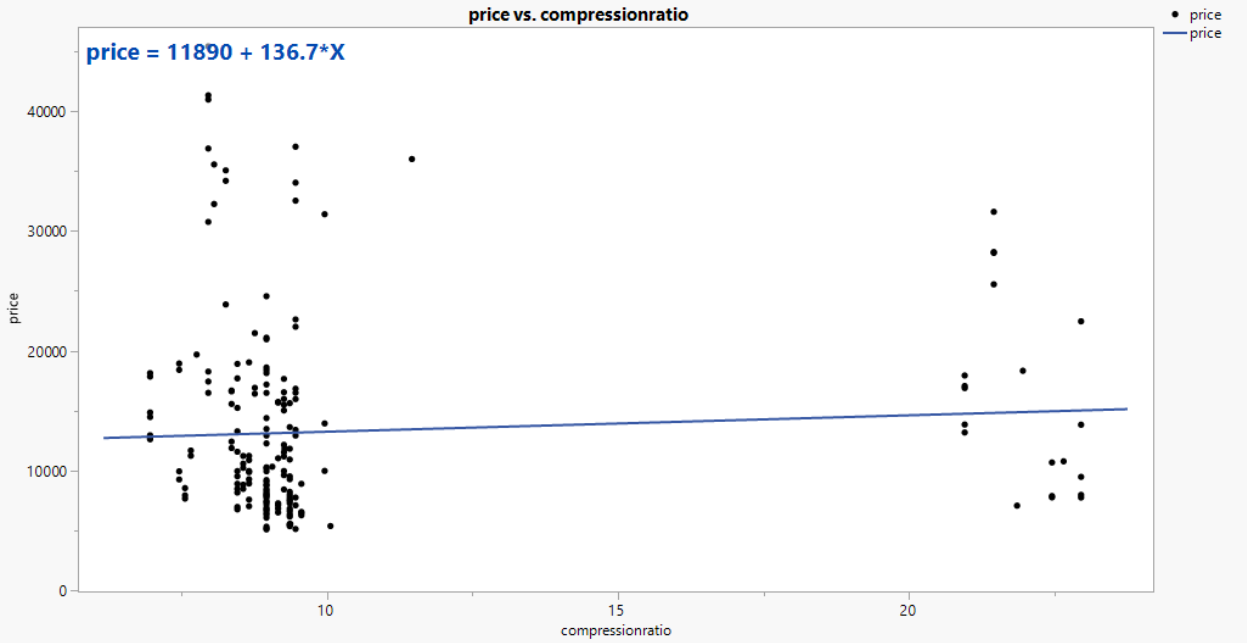
- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین Stroke خودرو با قیمت آن مستقیم
- ✓ با افزایش Stroke خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش Stroke خودرو، میانگین قیمت خودرو ۲۰۲۴ دلار افزایش می‌یابد.



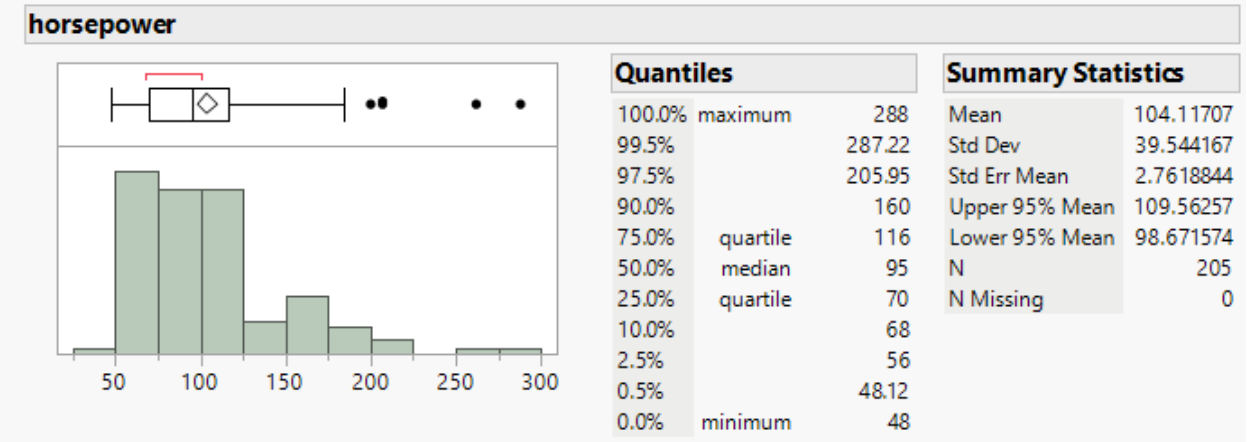
- **Compresionration (نسبت تراکم بین حجم سیلندر و محفظه احتراق در یک موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۷ تا ۲۳
  - ✓ مقدار Compresionration خودروها به طور متوسط (میانگین داده‌ها): ۱۰.۱۴
  - ✓ انحراف معیار داده‌ها: ۳.۹۷



- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین Compresionration خودرو با قیمت آن مستقیم
- ✓ با افزایش Compresionration خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش Compresionration خودرو، میانگین قیمت خودرو ۱۳۶.۷ دلار افزایش می‌یابد.



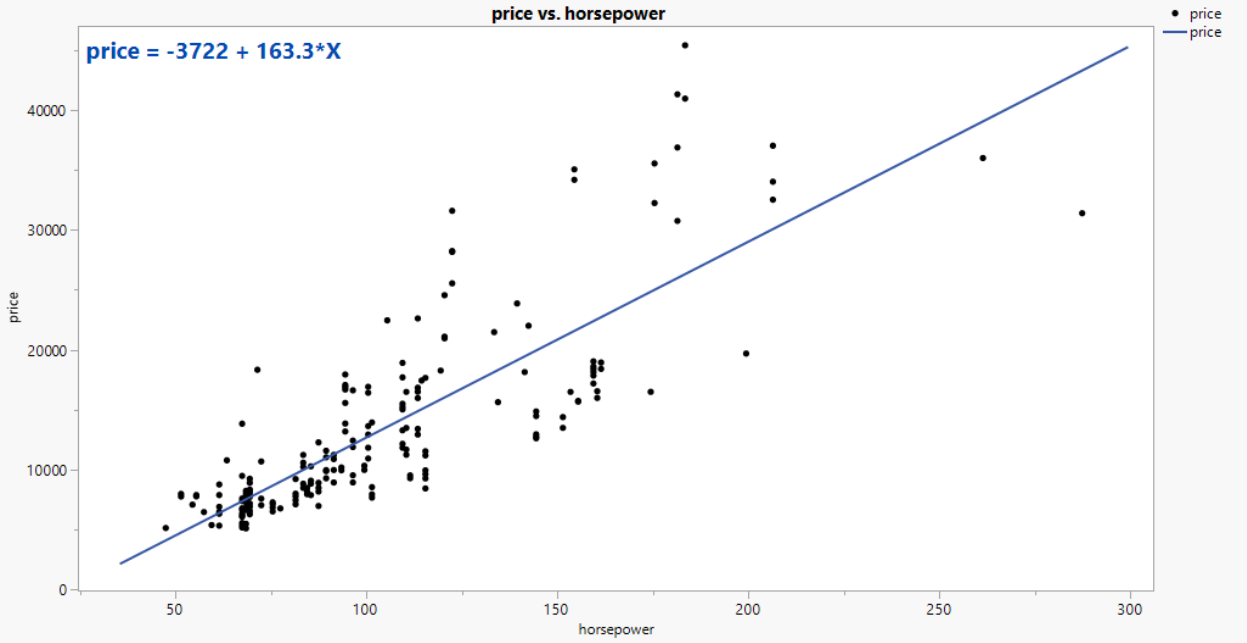
- **Horsepower (اسب بخار (قدرت) موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۴۸ تا ۲۸۸
  - ✓ مقدار قدرت موتور خودروها به طور متوسط (میانگین داده‌ها): ۱۰۴.۱ اسب بخار
  - ✓ انحراف معیار داده‌ها: ۳۹.۵



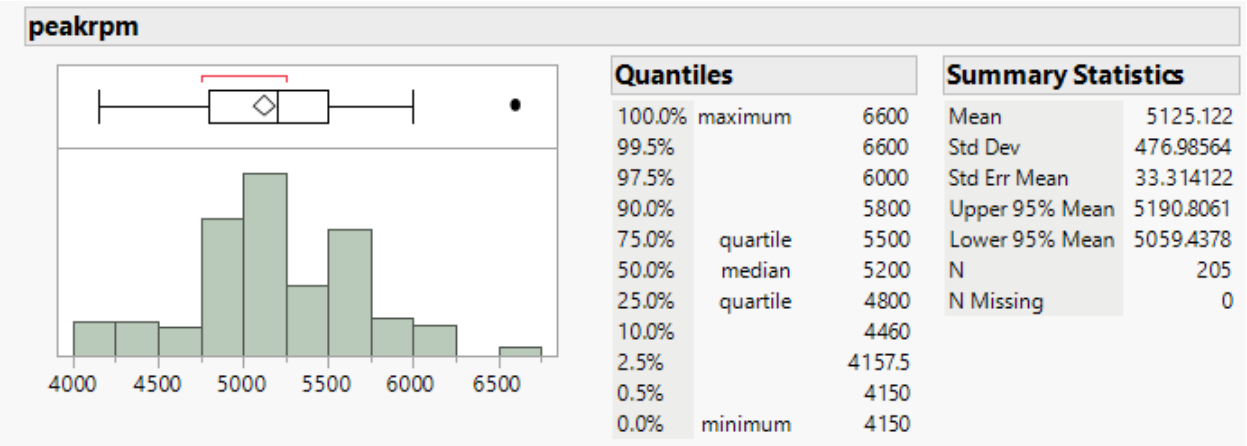
Quantiles		
100.0%	maximum	288
99.5%		287.22
97.5%		205.95
90.0%		160
75.0%	quartile	116
50.0%	median	95
25.0%	quartile	70
10.0%		68
2.5%		56
0.5%		48.12
0.0%	minimum	48

Summary Statistics	
Mean	104.11707
Std Dev	39.544167
Std Err Mean	2.7618844
Upper 95% Mean	109.56257
Lower 95% Mean	98.671574
N	205
N Missing	0

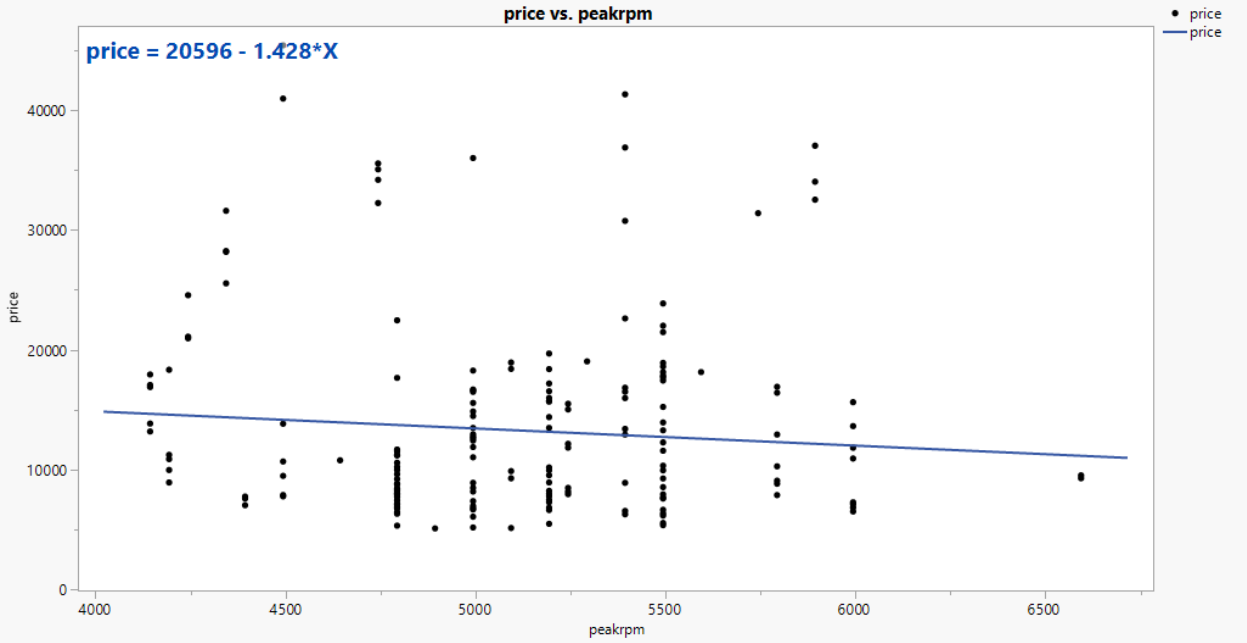
- ✓ شیب خط رگرسیون مثبت و صعودی
- ✓ رابطه بین قدرت موتور خودرو با قیمت آن مستقیم
- ✓ با افزایش قدرت موتور خودرو، قیمت خودرو نیز افزایش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش قدرت موتور خودرو، میانگین قیمت خودرو ۱۶۳.۳ دلار افزایش می‌یابد.



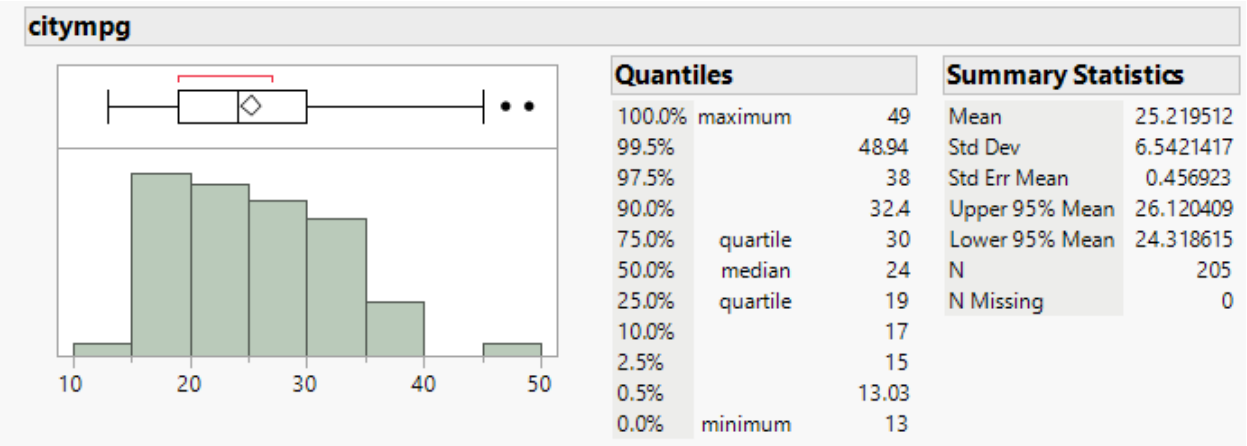
- **Peakrpm (گشتاور موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۴۱۵۰ تا ۶۶۰۰
  - ✓ مقدار گشتاور موتور خودروها به طور متوسط (میانگین داده‌ها): ۵۱۲۵
  - ✓ انحراف معیار داده‌ها: ۴۷۶.۹



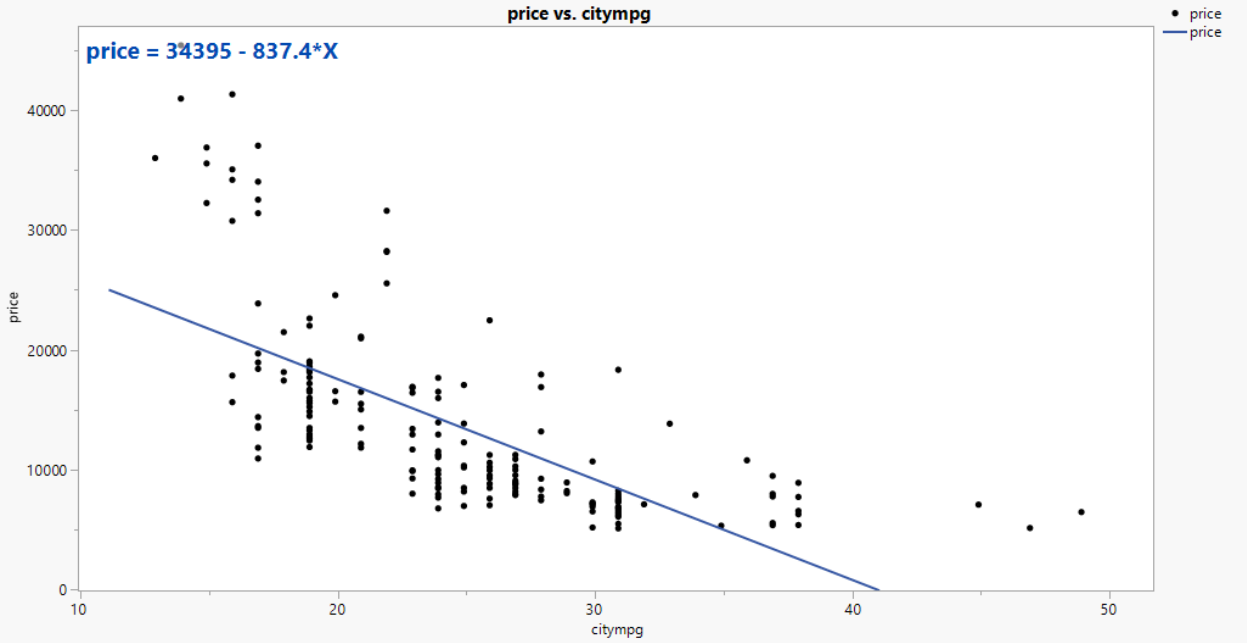
- ✓ شیب خط رگرسیون منفی و نزولی
- ✓ رابطه بین گشتاور موتور خودرو با قیمت آن عکس هم
- ✓ با افزایش گشتاور موتور خودرو، قیمت خودرو کاهش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش گشتاور موتور خودرو، میانگین قیمت خودرو ۱.۴۲۸ دلار کاهش می‌یابد.



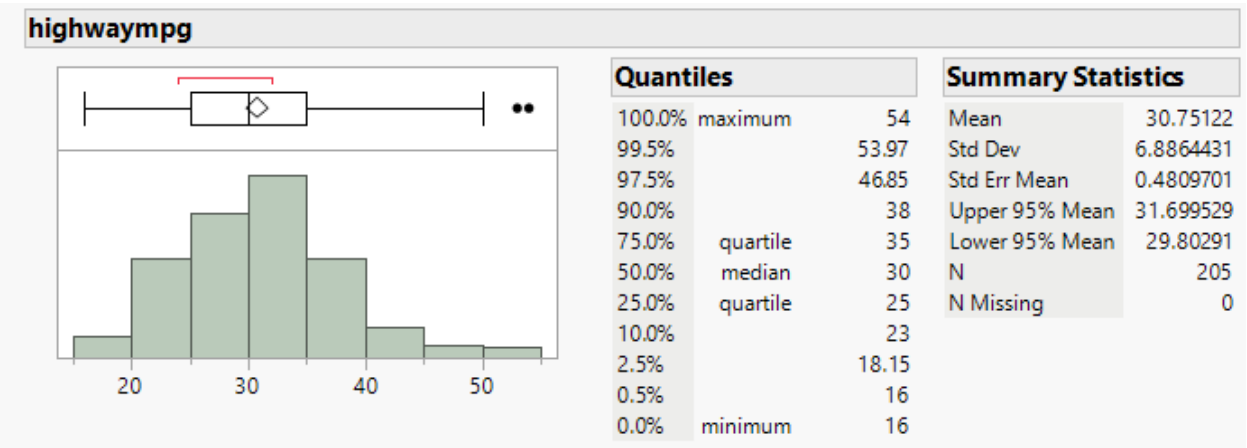
- **Citympg (مصرف سوخت شهری)**
- متغیر Numerical
- بازه مقادیر داده: از ۱۳ تا ۴۹
- مقدار مصرف سوخت شهری خودروها به طور متوسط (میانگین داده‌ها): ۲۵.۲
- انحراف معیار داده‌ها: ۶.۵۴



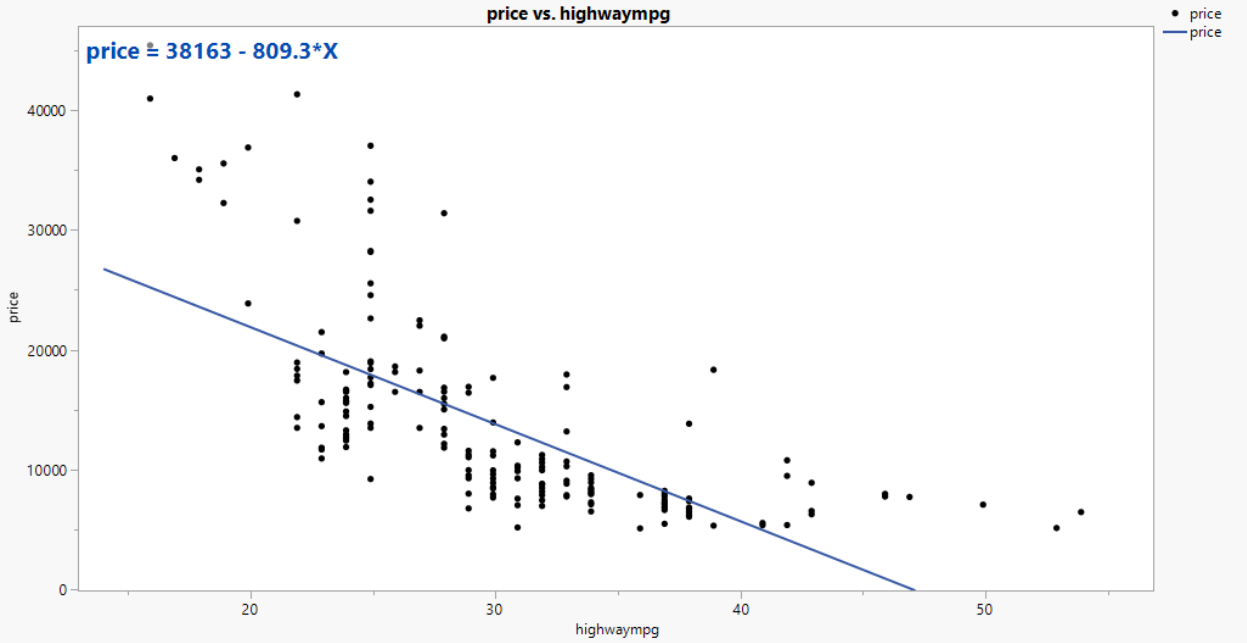
- ✓ شیب خط رگرسیون منفی و نزولی
- ✓ رابطه بین مصرف سوخت شهری خودرو با قیمت آن عکس هم
- ✓ با افزایش مصرف سوخت شهری خودرو، قیمت خودرو کاهش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش مصرف سوخت شهری خودرو، میانگین قیمت خودرو ۸۳۷.۴ دلار کاهش می‌یابد.



- **Highwarm (دمای کارکرد موتور)**
  - ✓ متغیر Numerical
  - ✓ بازه مقادیر داده: از ۱۶ تا ۵۴
  - ✓ مقدار دمای کارکرد موتور خودروها به طور متوسط (میانگین داده‌ها): ۳۰.۷
  - ✓ انحراف معیار داده‌ها: ۶.۸



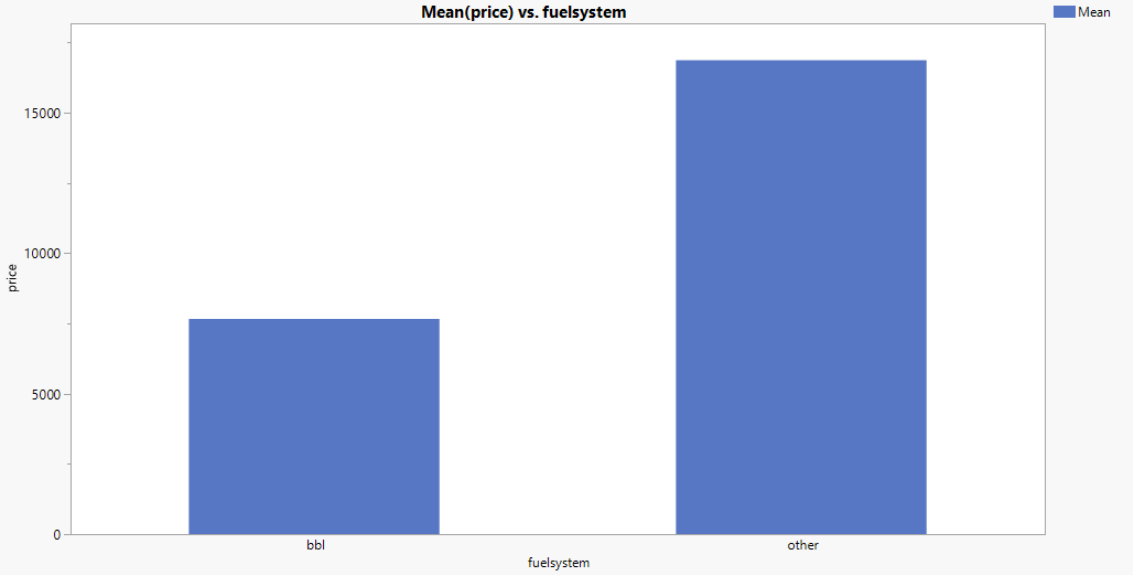
- ✓ شیب خط رگرسیون منفی و نزولی
- ✓ رابطه بین دمای کارکرد موتور خودرو با قیمت آن عکس هم
- ✓ با افزایش دمای کارکرد موتور خودرو، قیمت خودرو کاهش می‌یابد.
- ✓ بر اساس معادله خط زیر، با هر ۱ واحد افزایش دمای کارکرد موتور خودرو، میانگین قیمت خودرو ۸۰۹.۳ دلار کاهش می‌یابد.



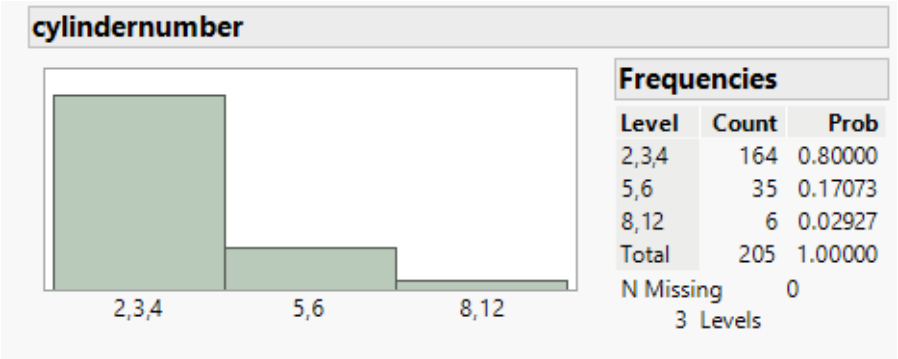
- **Fuel system (نوع تزریق سیستم سوخت)**
  - ✓ متغیر Categorical
  - ✓ دارای ۲ دسته‌بندی bbl و دیگر روش‌ها
  - ✓ ۶۰ درصد از انواع تزریق سیستم سوخت، در دسته‌بندی دیگر روش‌ها جای گرفته است.



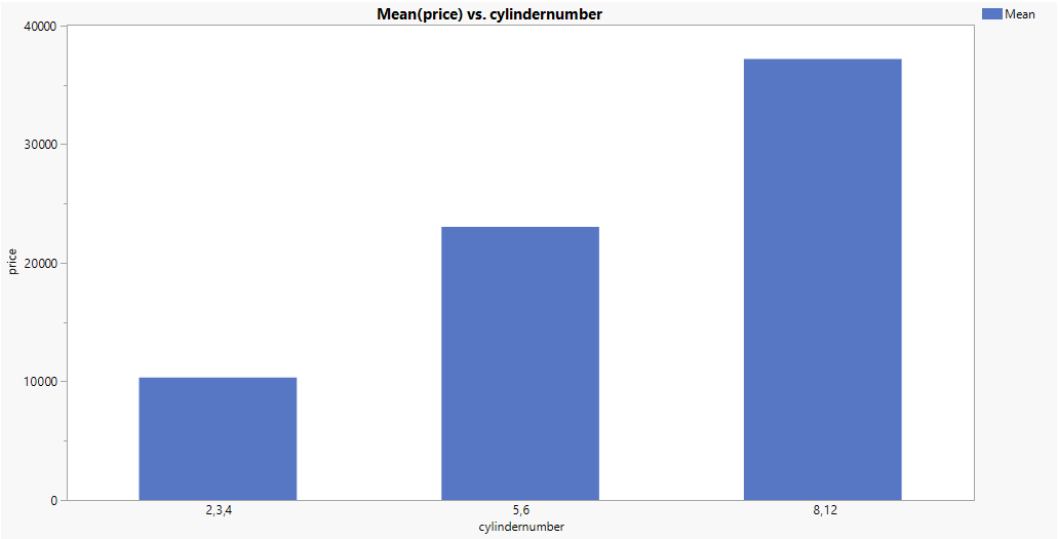
به طور متوسط خودروهایی که نوع تزریق سیستم سوختشان غیر از روش bbl است، قیمتشان بالاتر است.



- **Cylinder number (تعداد سیلندرها)**
  - ✓ متغیر Categorical
  - ✓ دارای ۳ دسته‌بندی "۸،۱۲"، "۵،۶" و "۲،۳،۴"
  - ✓ پرتکرارترین تعداد سیلندر در خودروها ۲،۳،۴ است با میزان ۸۰ درصد.



هر چه تعداد سیلندرهای خودرو بیشتر باشد، قیمت آن نیز افزایش می‌یابد.



ب) تعیین عوامل اثرگذار

عوامل اثرگذار بر قیمت با استفاده از مدل رگرسیون خطی چندگانه و بر اساس مقدار معیار p-value تعیین شدند؛ متغیرهایی که مقدار p-value آن‌ها کمتر یا مساوی ۰.۱۰ بود به‌عنوان عوامل معنادار در نظر گرفته شدند.

مقادیر p-value متغیرها در جدول زیر آمده است.

Effect Summary

Source	Logworth	PValue
enginetype	10.434	0.00000
enginesize	7.577	0.00000
stroke	4.630	0.00002
peakrpm	4.092	0.00008
enginelocation	3.378	0.00042
carbody	2.955	0.00111
cylindernumber	2.832	0.00147
carheight	1.784	0.01645
compressionratio	1.614	0.02433
fueltype	1.404	0.03945
drivewheel	1.396	0.04022
carwidth	1.383	0.04142
curbweight	1.364	0.04327
aspiration	1.259	0.05511
highwaympg	1.059	0.08740
boreratio	0.529	0.29575
wheelbase	0.248	0.56445
carlength	0.215	0.61015
citympg	0.174	0.67032
horsepower	0.105	0.78474
fuelsystem	0.099	0.79642
doornumber	0.003	0.99237

پس از حذف عواملی که اثر معناداری ندارند، به جدول زیر می‌رسیم.

Effect Summary

Source	Logworth	PValue
enginetype	11.552	0.00000
enginesize	9.202	0.00000
cylindernumber	6.568	0.00000
peakrpm	4.982	0.00001
stroke	4.910	0.00001
enginelocation	3.915	0.00012
carbody	3.357	0.00044
carheight	2.425	0.00376
highwaympg	2.363	0.00433
compressionratio	1.804	0.01571
fueltype	1.634	0.02320
aspiration	1.593	0.02552
drivewheel	1.589	0.02578
carwidth	1.567	0.02708
curbweight	1.497	0.03185

ج) تعیین عوامل دارای اثرات متقابل

اثرات متقابل بین عوامل با افزودن intraction بین هر دو عامل به مدل رگرسیون بررسی شد؛ به این معنا که آیا اثر یک عامل بر قیمت (رابطه بین یک عامل با قیمت)، به مقدار عامل دیگری وابسته است یا خیر.

از آنجایی که در این مدلسازی، پیشبینی و دقت مدل بسیار حائز اهمیت است، از روش k-fold استفاده کردیم (k=10) و از میان تمامی intractionهای ممکن، فقط اثرات متقابلی که در مدل اثرگذار هستند را نگه داشتیم به طوری که مقدار RSquare (R^2) بیشترین مقدار ممکن را بگیرد.

Step History

Step	Parameter	Action	"Sig Prob"	Seq SS	RSquare	Cp	p	AICc	BIC	RSquare K-Fold
1	enginesize	Entered	0.0000	9.949e+9	0.7641	2322.3	2	3974.94	3984.79	0.7605
2	enginetype{ohc&rotor&ohcf&l-dohc&ohcv}*cylindernumber{5,6-8,12}	Entered	0.0000	1.038e+9	0.8438	1477.6	6	3898.85	3921.54	0.8310
3	drivewheel{fwd&4wd-rwd}	Entered	0.0000	3.996e+8	0.8745	1151.2	7	3856.16	3882	0.8586
4	drivewheel{fwd&4wd-rwd}*(citympg-25.2195)	Entered	0.0000	3.675e+8	0.9028	853.31	9	3808.32	3840.41	0.8871
5	curbweight	Entered	0.0000	1.485e+8	0.9142	733.29	10	3784.97	3820.16	0.8990
6	(horsepower-104.117)*cylindernumber{5,6-8,12}	Entered	0.0000	2.035e+8	0.9298	570.05	12	3748.3	3789.59	0.9111
7	(enginesize-126.907)*cylindernumber{2,3,4-5,6&8,12}	Entered	0.0000	84799762	0.9363	502.37	13	3730.64	3774.95	0.9138
8	carwidth	Entered	0.0001	62703573	0.9411	452.85	14	3716.85	3764.16	0.9207
9	(curbweight-2555.57)*enginetype{dohc-ohcv}	Entered	0.0002	67090505	0.9463	401.72	16	3702.81	3756.03	0.9311
10	carbody{convertible-hardtop}*enginetype{ohc&rotor&ohcf&l-dohc&ohcv}	Entered	0.0030	63389396	0.9511	355.63	19	3690.63	3752.52	0.9366
11	(wheelbase-98.7566)*enginetype{ohc-rotor&ohcf&l}	Entered	0.0030	48193217	0.9548	322.03	22	3682.01	3752.34	0.9379
12	carbody{hatchback&wagon&sedan-convertible&hardtop}*enginetype{ohc-rotor&ohcf&l}	Entered	0.0038	26521661	0.9569	302.24	23	3675.11	3748.2	0.9407
13	(boreratio-3.32976)*(boreratio-3.32976)	Entered	0.0212	23514833	0.9587	286.92	25	3671.56	3750.07	0.9379
14	carbody{hatchback&wagon-sedan}	Entered	0.0064	21944266	0.9604	270.89	26	3665.67	3746.85	0.9394
15	drivewheel{fwd&4wd-rwd}*cylindernumber{2,3,4-5,6&8,12}	Entered	0.0136	17391472	0.9617	258.6	27	3661.33	3745.15	0.9387
16	(citympg-25.2195)*(citympg-25.2195)	Entered	0.0001	43665116	0.9651	224.72	28	3645.25	3731.68	0.9461
17	(wheelbase-98.7566)*(carheight-53.7249)	Entered	0.0227	19257008	0.9665	212.9	30	3641.91	3733.45	0.9445
18	compressionratio	Entered	0.0193	13530660	0.9676	203.78	31	3638.25	3732.31	0.9450
19	(highwaympg-30.7512)*fuelsystem{bbl-other}	Entered	0.0164	24544054	0.9695	189.61	34	3634.6	3735.99	0.9458
20	aspiration{std-turbo}*enginetype{ohc-rotor&ohcf&l}	Entered	0.0226	17432936	0.9708	179.29	36	3631.33	3737.45	0.9470
21	aspiration{std-turbo}*drivewheel{fwd-4wd}	Entered	0.0583	12715924	0.9718	172.84	38	3630.43	3741.12	0.9468
22	(carheight-53.7249)*enginetype{dohc-ohcv}	Entered	0.0433	8955876	0.9725	167.48	39	3628.46	3741.38	0.9465
23	enginetype{ohc-rotor&ohcf&l}*(peakrpm-5125.12)	Entered	0.0697	11453948	0.9734	162.07	41	3628.1	3745.37	0.9467
24	(peakrpm-5125.12)*(peakrpm-5125.12)	Entered	0.0758	6668041	0.9739	158.59	42	3627.32	3746.71	0.9481
25	stroke	Entered	0.0235	10643335	0.9747	151.84	43	3624.06	3745.52	0.9491
26	enginetype{dohc-ohcv}*(stroke-3.25541)	Entered	0.0448	8165942	0.9753	147.13	44	3622.2	3745.7	0.9516
27	(boreratio-3.32976)*(peakrpm-5125.12)	Entered	0.0602	7039321	0.9759	143.35	45	3620.99	3746.48	0.9495
28	drivewheel{fwd-4wd}*enginetype{dohc-ohcv}	Entered	0.0528	7350444	0.9764	139.31	46	3619.51	3746.96	0.9507
29	drivewheel{fwd&4wd-rwd}*enginetype{ohc-rotor&ohcf&l}	Entered	0.0435	7847143	0.9770	134.86	47	3617.62	3746.97	0.9523
30	(stroke-3.25541)*(peakrpm-5125.12)	Entered	0.0594	6716242	0.9775	131.34	48	3616.43	3747.64	0.9529
31	(carwidth-65.9078)*(curbweight-2555.57)	Entered	0.0913	5315126	0.9779	128.98	49	3616.17	3749.21	0.9527
32	(wheelbase-98.7566)*(carwidth-65.9078)	Entered	0.1376	4068388	0.9783	127.63	50	3616.8	3751.6	0.9503
33	(wheelbase-98.7566)*(wheelbase-98.7566)	Entered	0.0103	11878607	0.9792	119.87	51	3611.61	3748.14	0.9511
34	(carlength-174.049)*cylindernumber{2,3,4-5,6&8,12}	Entered	0.0156	14451221	0.9803	112	53	3607.72	3747.56	0.9539
35	(wheelbase-98.7566)*cylindernumber{2,3,4-5,6&8,12}	Entered	0.0185	9297153	0.9810	106.36	54	3603.9	3745.33	0.9414
36	(wheelbase-98.7566)*enginetype{ohc&rotor&ohcf&l-dohc&ohcv}	Entered	0.0124	10147654	0.9818	100.02	55	3599.11	3742.07	0.9495
37	(carheight-53.7249)*(stroke-3.25541)	Entered	0.0350	6999701	0.9823	96.27	56	3596.82	3741.25	0.9512
38	(curbweight-2555.57)*cylindernumber{2,3,4-5,6&8,12}	Entered	0.0634	5319549	0.9827	93.899	57	3595.93	3741.79	0.9529
39	(enginesize-126.907)*(citympg-25.2195)	Entered	0.0277	7323131	0.9833	89.881	58	3593.1	3740.33	0.9563
40	enginetype{dohc-ohcv}*(citympg-25.2195)	Entered	0.0694	4877321	0.9837	87.874	59	3592.46	3741	0.9577
41	(carlength-174.049)*(citympg-25.2195)	Entered	0.1395	3191157	0.9839	87.252	60	3593.42	3743.23	0.9547
42	(wheelbase-98.7566)*fuelsystem{bbl-other}	Entered	0.0316	6640560	0.9844	83.795	61	3590.94	3741.95	0.9597
43	(wheelbase-98.7566)*(citympg-25.2195)	Entered	0.0657	4769586	0.9848	81.876	62	3590.24	3742.4	0.9590
44	(wheelbase-98.7566)*(highwaympg-30.7512)	Entered	0.0346	6158707	0.9852	78.816	63	3588.01	3741.26	0.9581
45	fueltype{gas-diesel}	Entered	0.0422	5560842	0.9857	76.246	64	3586.29	3740.56	0.9581
46	drivewheel{fwd&4wd-rwd}*enginetype{ohc&rotor&ohcf&l-dohc&ohcv}	Entered	0.1335	2985451	0.9859	75.793	65	3587.34	3742.57	0.9620
47	carbody{convertible-hardtop}*(enginesize-126.907)	Entered	0.1020	3508136	0.9862	74.911	66	3587.81	3743.94	0.9606
48	(carwidth-65.9078)*enginetype{ohc&rotor&ohcf&l-dohc&ohcv}	Entered	0.1917	2217288	0.9863	75.089	67	3589.75	3746.72	0.9351
49	(curbweight-2555.57)*(peakrpm-5125.12)	Entered	0.1844	2280329	0.9865	75.215	68	3591.66	3749.4	0.9468
50	carbody{hatchback&wagon&sedan-convertible&hardtop}*enginetype{ohc&rotor&ohcf&l-dohc&ohcv}	Entered	0.1764	2351576	0.9867	75.283	69	3593.52	3751.95	0.9398
51	carbody{convertible-hardtop}*enginetype{ohc-rotor&ohcf&l}	Entered	0.1156	3158492	0.9869	74.688	70	3594.44	3753.5	0.9300
52	(wheelbase-98.7566)*(peakrpm-5125.12)	Entered	0.1687	2395387	0.9871	74.719	71	3596.3	3755.92	0.9293
53	enginetype{ohc&rotor&ohcf&l-dohc&ohcv}*(peakrpm-5125.12)	Entered	0.1637	2435989	0.9873	74.718	72	3598.13	3758.24	0.9204
54	(curbweight-2555.57)*(compressionratio-10.1425)	Entered	0.0989	3386046	0.9876	73.936	73	3598.8	3759.31	0.9224
55	fueltype{gas-diesel}*enginetype{rotor&ohcf-l}	Entered	0.0552	7053597	0.9881	72.14	75	3599.71	3760.82	0.8787
56	(carwidth-65.9078)*(compressionratio-10.1425)	Entered	0.0880	3465761	0.9884	71.292	76	3600.21	3761.5	0.8981
57	Best	Specific	.	.	0.9859	75.793	65	3587.34	3742.57	0.9620

خلاصه نتایج به‌دست آمده:

SSE	DFE	RMSE	RSquare	RSquare Adj	Cp	p	AICc	BIC	RSquare K-Fold
256525693	158	1274.1979	0.9803	0.9746	34.588396	47	3586.063	3715.414	0.9636

د) ارائه مدل در جهت پیش‌بینی قیمت خودروهای جیلی

تعداد Predictorهای مدل: ۲۲ مورد

ابتدا مشابه "بخش ب" مدل رگرسیون خطی چندگانه (Multiple Linear Regression) می‌زنیم.

R^2 = 0.9263

R^2_{adj} = 0.9132

Summary of Fit	
RSquare	0.926394
RSquare Adj	0.913205
Root Mean Square Error	2353.598
Mean of Response	13276.71
Observations (or Sum Wgts)	205

برای بهبود این مدل و افزایش مقدار RSquare، مشابه "بخش ج" intractionهای بین Predictorها را نیز وارد مدل کرده (Stepwise Regression) و با کمک یک شاخص validation مانند k-fold که بتواند مدل مناسبی برای پیش‌بینی به ما ارائه دهد، مدل رگرسیون چندجمله‌ای (Polynomial Regression) می‌زدیم.

اطلاعات حاصل بعد از اعمال شاخص k-fold:

R^2 = 0.9859

SSE	DFE	RMSE	RSquare	RSquare Adj	Cp	p	AICc	BIC	RSquare K-Fold
183517864	140	1144.92	0.9859	0.9795	75.793373	65	3587.338	3742.57	0.9620

با استفاده از ضرایب بدست آمده حاصل از اعمال شاخص k-fold، مدلی زده شد که مقدار RSquare نهایی حاصل از آن، ۰.۹۹۳۵ بدست آمد که مقدار بسیار خوبی است. از طرفی چون اختلاف R^2 با R^2_{adj} کمتر از ۱ درصد (۰.۰۱۲٪) است، مدل ما overfit نیز نشده است.

Summary of Fit	
RSquare	0.99355
RSquare Adj	0.981468
Root Mean Square Error	1087.535
Mean of Response	13276.71
Observations (or Sum Wgts)	205

R^2 = 0.9935

R^2_{adj} = 0.9814

RMSE = 1087.5

اسامی Predictorها و Interactionهای موثر نهایی:

fueltype	aspiration	doornumber
carbody	drivewheel	enginelocation
wheelbase	carlength	carwidth
carheight	curbweight	enginetype
enginesize	boreratio	stroke
compressionratio	horsepower	peakrpm
citympg	highwaympg	fuelsystem
cylindernumber	fueltype*enginetype	aspiration*doornumber
aspiration*carbody	aspiration*drivewheel	aspiration*carheight
aspiration*enginetype	doornumber*wheelbase	doornumber*enginetype
doornumber*boreratio	doornumber*peakrpm	carbody*carheight
carbody*enginetype	carbody*enginesize	drivewheel*enginetype
drivewheel*citympg	drivewheel*cylindernumber	wheelbase*wheelbase
wheelbase*carlength	wheelbase*carwidth	wheelbase*carheight
wheelbase*curbweight	wheelbase*enginetype	wheelbase*enginesize
wheelbase*boreratio	wheelbase*stroke	wheelbase*compressionratio
wheelbase*horsepower	wheelbase*peakrpm	wheelbase*citympg
wheelbase*highwaympg	wheelbase*fuelsystem	wheelbase*cylindernumber
carlength*stroke	carlength*horsepower	carlength*peakrpm
carlength*citympg	carlength*cylindernumber	carwidth*curbweight
carwidth*enginetype	carwidth*compressionratio	carwidth*citympg
carheight*enginetype	carheight*stroke	curbweight*enginetype
curbweight*compressionratio	curbweight*peakrpm	curbweight*citympg
curbweight*cylindernumber	enginetype*enginesize	enginetype*stroke
enginetype*compressionratio	enginetype*peakrpm	enginetype*citympg
enginetype*highwaympg	enginetype*cylindernumber	enginesize*citympg
enginesize*cylindernumber	boreratio*boreratio	boreratio*peakrpm
stroke*peakrpm	horsepower*horsepower	horsepower*citympg
horsepower*cylindernumber	peakrpm*peakrpm	peakrpm*citympg
citympg*citympg	highwaympg*fuelsystem	

مدل نهایی بر اساس حداقل خطای پیش‌بینی در اعتبارسنجی K-Fold انتخاب شد.

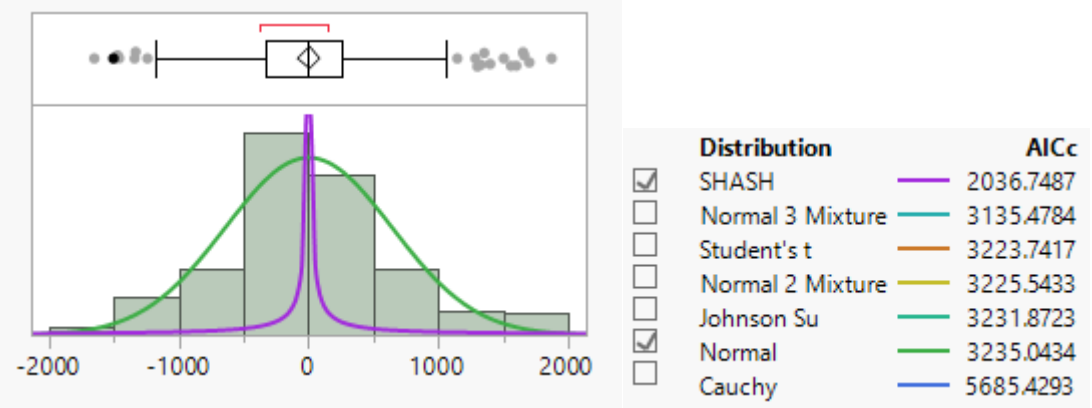
با توجه به تعداد بالای متغیرها و وجود اثرات متقابل، معادله‌ی کامل مدل به دلیل طولانی بودن در متن اصلی گزارش ارائه نشده و در پیوست آورده شده است. تمرکز اصلی بر عملکرد و دقت پیش‌بینی مدل بوده است.

۵) بررسی کفایت و اعتبار مدل

پس از به برآورد پارامترهای مدل، فرضیه‌هایی که این مدل رگرسیونی بر آن استوار است را نیز بررسی می‌کنیم.

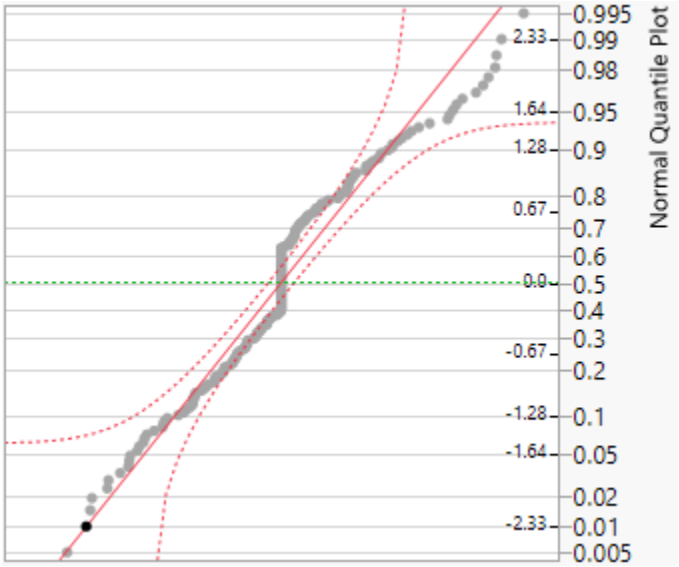
1 . بررسی نرمال بودن خطاهای پیشبینی (Normality of residuals)

ابتدا روی ستون Residual ها یک تحلیل انجام می‌دهیم.



طبق نمودار بالا چون داده‌ها خیلی چوله نیستند، نرمال به نظر می‌آیند.

اما با رسم نمودار نرمالیتی داده‌ها متوجه می‌شویم یک سری از داده‌ها هم با خط وسط فاصله دارند و هم از محدوده مشخص شده خارج شده‌اند.



برای بررسی دقیق‌تر، به سراغ آزمون‌های آماری می‌رویم.

در این قسمت فرض نرمال بودن داده‌ها به طور علمی رد می‌شود چون مقدار P-value آن‌ها بسیار پایین است. (کمتر از ۰.۰۵)

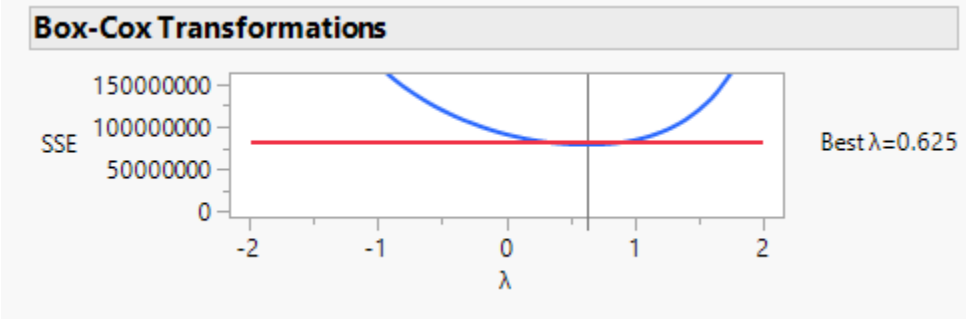
Goodness-of-Fit Test

	W	Prob<W
Shapiro-Wilk	0.9566168	<.0001*

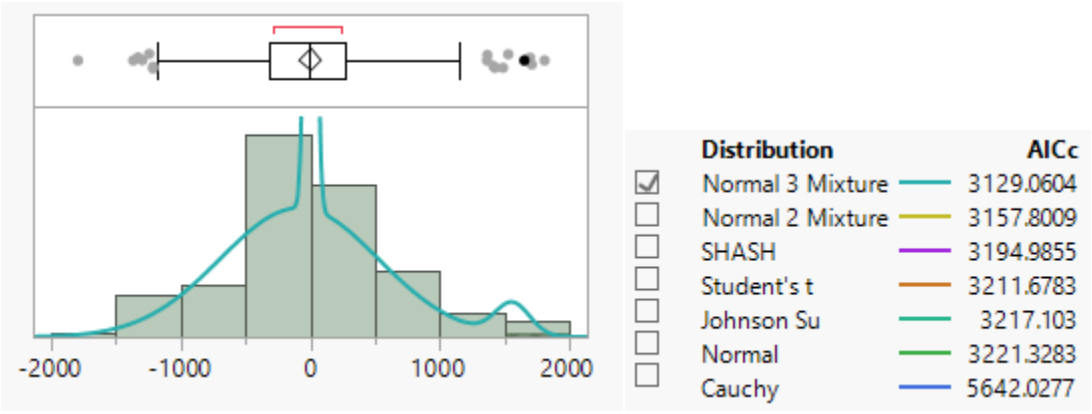
	A^2	Simulated p-Value
Anderson-Darling	4.1784758	<.0001*

Note: Ho = The data is from the Normal distribution. Small p-values reject Ho.

حال با استفاده از تبدیل Box-Cox (تبدیل توانی) به جای y، تابعی از آن را مدل می‌کنیم.

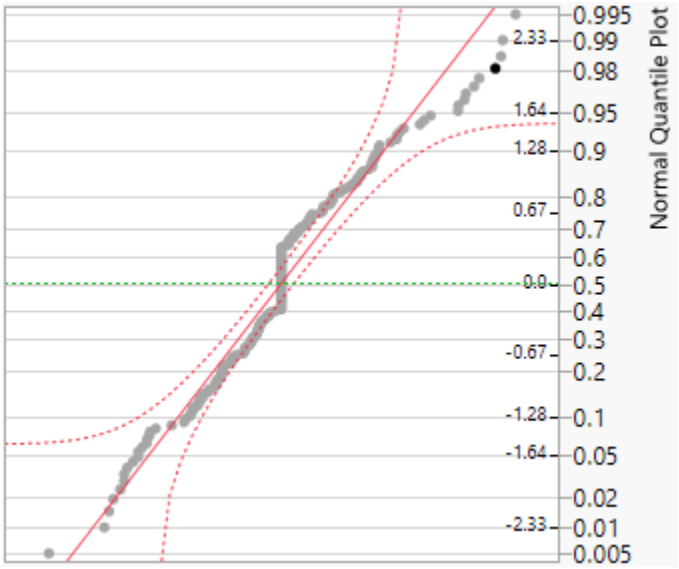


بهترین مقدار لاندا ۰.۶۲۵ پیشنهاد شده است، پس $y^{0.625}$ را این بار مدل می‌کنیم و مجدد توزیع Residual ها را بررسی می‌کنیم.



رسم مجدد نمودار نرمالیتی:

نرمالیتی داده‌ها تغییر اندکی نسبت به نمودار قبلی پیدا کردند و نقاط بیشتری داخل محدوده قرار گرفتند. این کم بودن تغییر به دلیل حضور داده‌های پرت است که در مراحل جلوتر با حذف آن‌ها نرمال شدن محسوس‌تر خواهد شد.



مجدد مقدار P-value را بررسی می‌کنیم که مشاهده می‌کنیم تغییر خاصی نکرده است و همچنان مقدار آن کمتر از ۰.۰۵ است.

Goodness-of-Fit Test

	W	Prob<W
Shapiro-Wilk	0.9614577	<.0001*

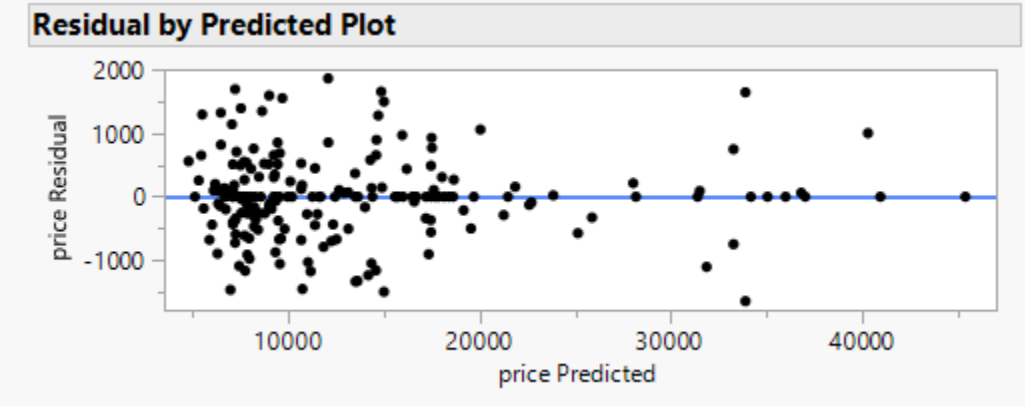
	A^2	Simulated p-Value
Anderson-Darling	3.5270362	<.0001*

Note: Ho = The data is from the Normal distribution. Small p-values reject Ho.

۲. بررسی واریانس همگن خطاهای پیشبینی (Heteroscedasticity)

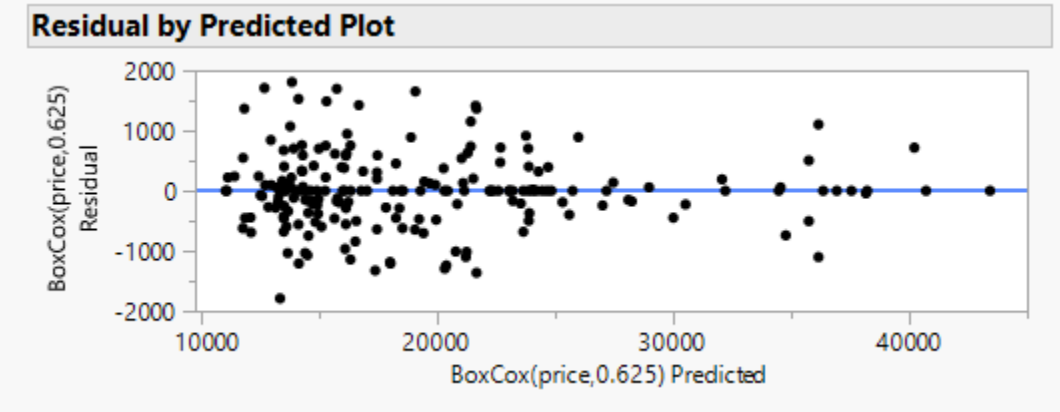
همان‌طور که در نمودار زیر مشخص است، با ناهمگونی واریانس مواجه هستیم که مشابه بخش قبلی، با استفاده از تبدیل Box-Cox می‌توانیم تا حدی این ناهمگونی را بهبود ببخشیم.

قبل از اعمال تبدیل Box-Cox:



در این مدل، هر چه قیمت خودروها بالاتر می‌رود، خطای آن‌ها بیشتر می‌شود.

بعد از اعمال تبدیل Box-Cox:

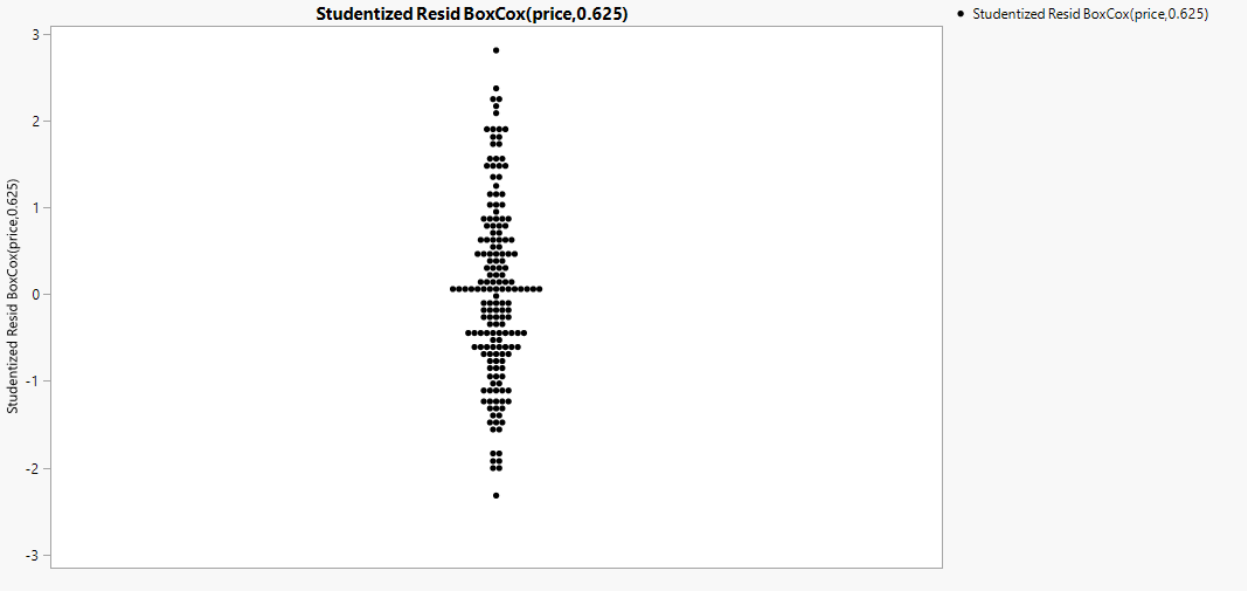


۳. بررسی نقاط پرت (Qutlier Detection)

در این مرحله می‌خواهیم روی مدلی که تا اینجا پیش بردیم، داده‌های پرت را تشخیص دهیم.

الف) داده‌های پرت مربوط به Residualها

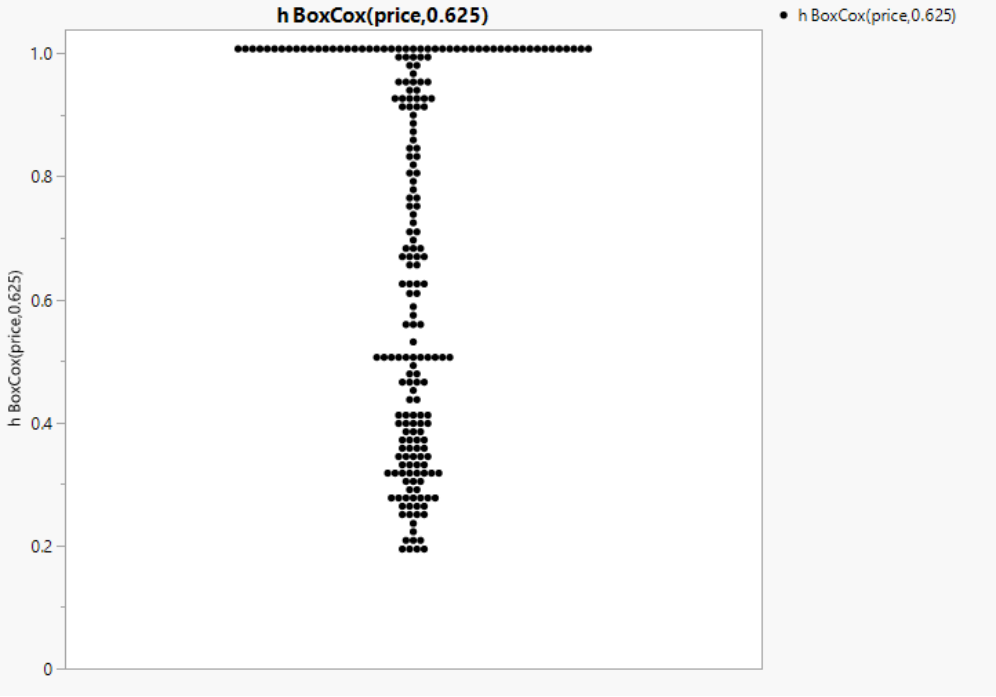
برای برخی مشاهدات به دلیل اهرم بالا و محدودیت‌های محاسباتی مدل، مقدار Studentized Residual قابل محاسبه نبود که در مدل‌های با تعداد بالای متغیر توضیحی امکان پیش آمدن این مورد دور از انتظار نیست.

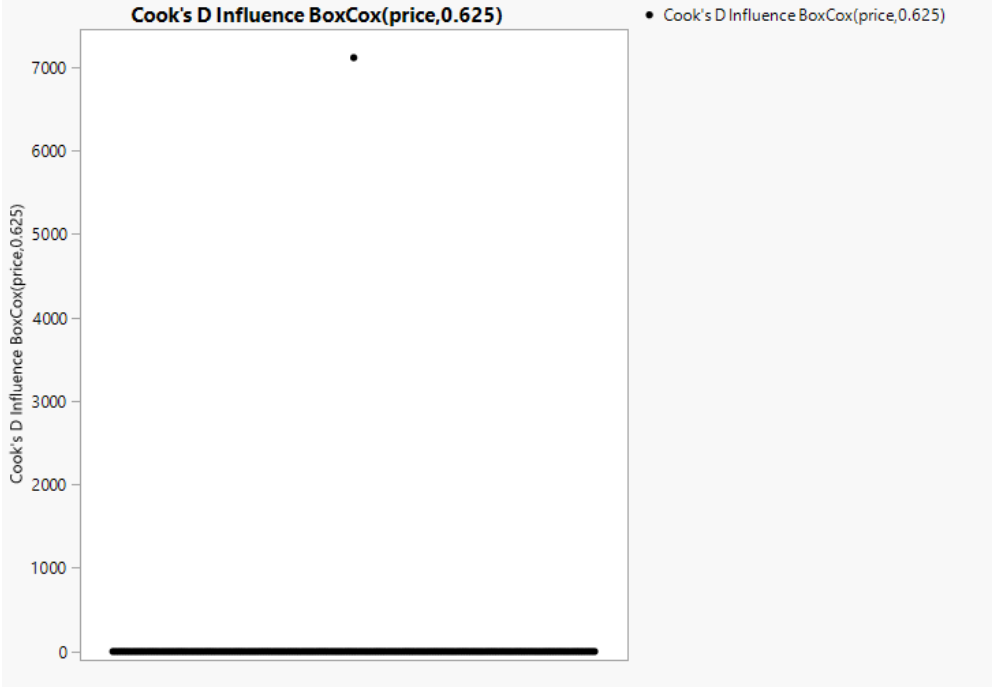


از آن‌جایی که تمامی داده‌های استاندارد شده در بازه عددی ۳ تا ۳- قرار گرفته‌اند، داده پرت (Outlier) خارج از این محدوده نداریم.

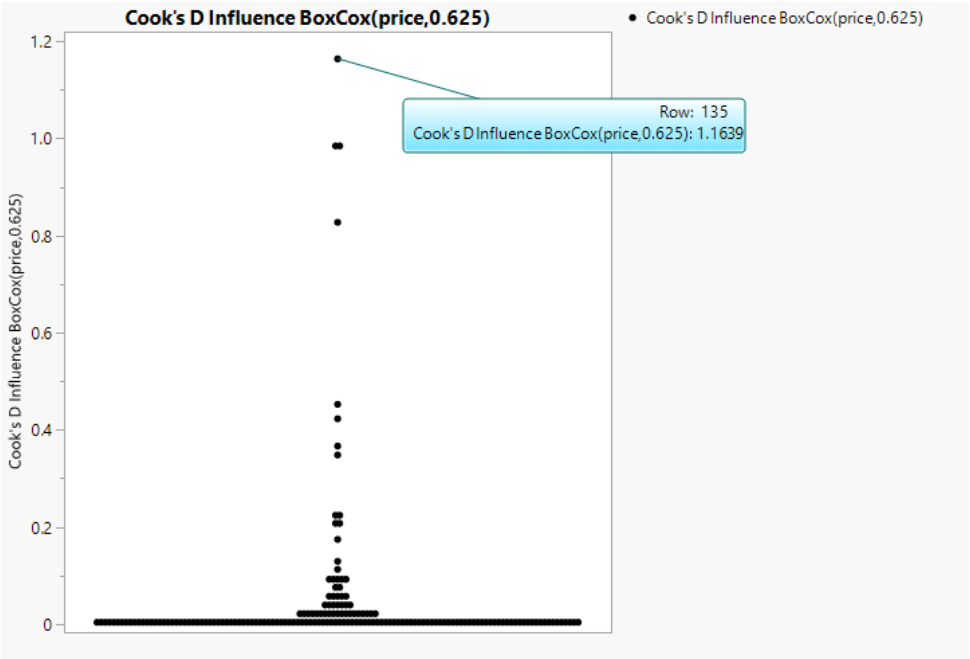
ب) داده‌های پرت مربوط به X

از بخش Hats و Cooks D Influence داده‌های پرت X را شناسایی می‌کنیم. شاخص Hats هم داده پرتی را به ما نشان نداد و همه داده‌ها بین ۰ تا ۱ هستند.



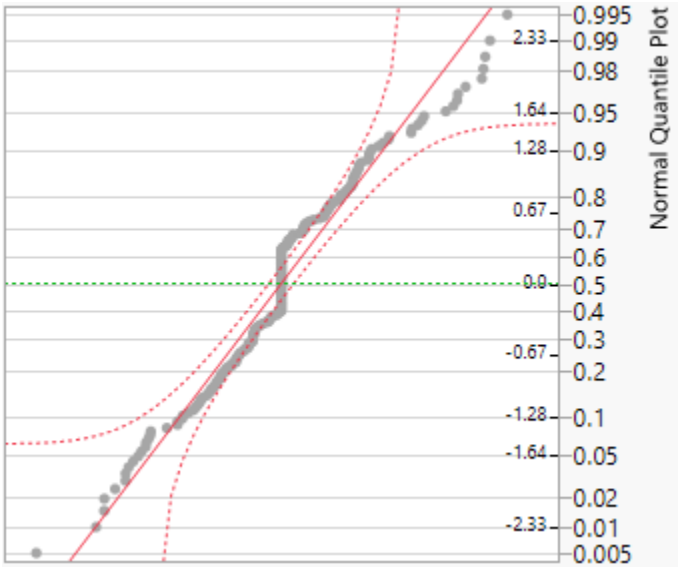


اما با توجه به شاخص Cooks D Influence یک داده بسیار پرت داریم (نقطه ۱۴۴) که خیلی بالاتر از ۱ است و مدل را تحت تاثیر خودش قرار داده و خراب می‌کند. بنابراین این داده پرت را حذف می‌کنیم و به نمودار زیر می‌رسیم.



حال که مقیاس کمتر شد و پراکندگی نقاط بیشتر نمایان شد، مشاهده می‌شود یک داده دیگر نیز مقدار آن بالاتر از ۱ است (نقطه ۱۳۵) که آن را نیز حذف می‌کنیم.

نمودار نرمالیتی نسبت به قبل کمی بهبود پیدا کرده است.



اما مقدار R^2 به میزان اندکی یعنی ۰.۰۱۲ و R^2_{adj} به میزان ۰.۰۰۴ کاهش پیدا کرده‌اند. ولی از طرفی مقدار RMSE کاهشی بوده و بهبود یافته است.

مقدار RSquare پیش از بررسی اعتبار مدل:

Summary of Fit	
RSquare	0.99355
RSquare Adj	0.981468
Root Mean Square Error	1087.535
Mean of Response	13276.71
Observations (or Sum Wgts)	205

مقدار RSquare بعد از بررسی اعتبار مدل:

Summary of Fit	
RSquare	0.992064
RSquare Adj	0.976767
Root Mean Square Error	1048.426
Mean of Response	19431.29
Observations (or Sum Wgts)	203

نتیجه‌گیری

در این مطالعه ابتدا با استفاده از آمار توصیفی عوامل مؤثر بر قیمت شناسایی شدند. سپس اثرات متقابل بررسی و در نهایت مدلی معتبر و بهینه برای پیش‌بینی قیمت خودروهای جیلی در بازار آمریکا ارائه گردید.